

TRƯỜNG ĐẠI HỌC ĐÀ LẠT
KHOA TOÁN - TIN HỌC



ĐỒ ÁN CƠ SỞ

TIẾP CẬN PHƯƠNG PHÁP LDA CỦA R.A. FISHER
TRONG PHÂN LOẠI MẪU THỐNG KÊ

Giảng viên hướng dẫn: **Đặng Phước Huy**

Huỳnh Bảo Tuyên

Sinh viên thực hiện: **Phùng Ngọc Bảo**

Mã số sinh viên: **2212318**

Lớp: **KLK46**

Lâm Đồng, tháng 6 năm 2026

TÓM TẮT

Đề tài tập trung nghiên cứu phương pháp phân tích biệt thức tuyến tính (LDA) của R.A. Fisher và khả năng ứng dụng của phương pháp này trong bài toán phân loại mẫu thống kê. Nội dung chính của đề án bao gồm việc trình bày cơ sở lý thuyết của LDA, phân tích nguyên lý tối ưu khả năng phân tách giữa các lớp dữ liệu, đồng thời triển khai thử nghiệm trên một số tập dữ liệu minh họa.

Trong quá trình thực hiện, đề án tiến hành khảo sát mô hình toán học của phương pháp, cách xây dựng hàm mục tiêu, ma trận phân tán trong lớp và giữa các lớp, từ đó xác định không gian chiếu tối ưu nhằm nâng cao khả năng phân loại. Bên cạnh đó, đề tài cũng thực hiện đánh giá kết quả thực nghiệm, so sánh khả năng phân tách dữ liệu trước và sau khi áp dụng LDA.

Kết quả nghiên cứu cho thấy phương pháp LDA có ý nghĩa quan trọng trong việc giảm chiều dữ liệu và hỗ trợ phân loại hiệu quả đối với các bài toán có cấu trúc lớp rõ ràng. Từ những kết quả đạt được, đề án góp phần làm rõ hơn giá trị lý thuyết cũng như khả năng ứng dụng thực tiễn của phương pháp LDA trong lĩnh vực phân tích dữ liệu và học máy.

Mục lục

Danh sách hình ảnh và biểu đồ	viii
Danh sách bảng	ix
1 Kiến thức chuẩn bị	1
1.1 Giới thiệu	1
1.1.1 Giới thiệu việc học thống kê	1
1.1.2 Tổng quan về việc học có giám sát	2
1.1.3 Bài toán phân loại mẫu	4
1.2 Mẫu từ vector đặc trưng nhiều chiều của quần thể	6
1.3 Phân tích tương quan và các moment đặc trưng mẫu	8
1.3.1 Các mô-men đặc trưng mẫu	8
1.3.2 Hệ số tương quan mẫu	9
1.3.3 Ma trận tương quan mẫu và hệ số tải	13
1.4 LDA trong tiếp cận của Fisher	18
1.4.1 Ý tưởng hình học của Fisher	19
1.4.2 Cơ sở lý thuyết theo LDA của Fisher	20
1.4.2.1 Ma trận tán xạ trong lớp và giữa các lớp	20
1.4.3 Tiêu chuẩn Fisher trong bài toán hai lớp	20
1.4.4 Nghiệm tối ưu của Fisher trong trường hợp hai lớp	21
1.4.4.1 Tìm độ lớn bằng bài toán Rayleigh	21
1.4.4.2 Tìm phương tối ưu bằng bất đẳng thức Cauchy–Schwarz	26
1.5 Lý thuyết quyết định Bayes trong bài toán phân loại	29
1.5.1 Xác suất hậu nghiệm và quy tắc Bayes tối ưu	29
1.5.2 Mô hình Gaussian cho các lớp	29
1.6 LDA trong cách tiếp cận của lý thuyết quyết định Bayes	30
1.6.1 Trường hợp cùng hiệp phương sai và sự xuất hiện của biên tuyến tính	30
1.6.2 Quy tắc phân loại LDA trong thực hành	31
1.6.3 Sự tương đương giữa Fisher và LDA theo Bayes	31
1.6.4 Minh họa phân loại một chiều trên bộ dữ liệu Iris	32

1.7	Xác định độ chính xác phân loại mẫu thống kê	38
1.7.1	Ma trận nhập nhằng	39
1.7.2	TPM – Total Probability of Misclassification	40
1.7.3	ECM – Expected Cost of Misclassification	41
1.7.4	Mối liên hệ giữa Accuracy, TPM và ECM	42
2	LDA cho bài toán phân loại hai lớp	45
2.1	Bài toán phân loại hai lớp	45
2.1.1	Thiết lập bài toán và giả thiết mô hình xác suất	45
2.1.2	Quy tắc phân loại Bayes cho bài toán hai lớp	45
2.1.3	Sự giao thoa và tương đương với tiếp cận của Fisher	46
2.1.4	Thủ tục Bayes Classifier trong thực nghiệm	47
2.1.5	Ví dụ minh họa: Bài toán phân loại hai chiều (Mô phỏng) . . .	48
2.1.5.1	Hai lớp không thể tách biệt bởi biên tuyến tính	48
2.1.5.2	Hai lớp là tách biệt hoàn toàn bởi một biên tuyến tính	55
	Tài liệu tham khảo	63

Danh sách hình ảnh và biểu đồ

1.1	Sơ đồ phân loại các phương pháp học thống kê.	2
1.2	Mô hình toán học máy học.	3
1.3	Hình chiếu trực giao của $\mathbf{x}_j^*$ lên $\langle \mathbf{1} \rangle$	11
1.4	Hình chiếu trực giao của hai vector $\mathbf{x}_j^*, \mathbf{x}_k^*$ lên $\langle \mathbf{1} \rangle$	12
1.5	Đồ thị đám mây điểm biểu diễn mức độ tương quan của hai vector $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$	13
1.6	Minh họa hình học cho hệ số tải	15
1.7	Ý tưởng hình học của Fisher để phân tách hai lớp tốt nhất, tham khảo [4].	19
1.8	Minh họa phân loại một chiều bằng LDA trên bộ dữ liệu Iris với hai lớp <i>versicolor</i> và <i>virginica</i> theo thuộc tính <i>Petal.Length</i>	34
1.9	Minh họa phân loại một chiều bằng LDA trên bộ dữ liệu Iris với hai lớp <i>setosa</i> và <i>versicolor</i> theo thuộc tính <i>Petal.Length</i>	37
2.1	Phân bố mẫu của hai lớp chuẩn hai chiều và đường phân loại LDA. . .	49
2.2	Ma trận nhập nhằng dùng để đánh giá kết quả phân loại của mô hình LDA.	50
2.3	Phân bố mẫu của hai lớp chuẩn hai chiều có tương quan dương và mức độ chồng lấn lớn.	52
2.4	Ma trận nhập nhằng của mô hình LDA trong trường hợp hai lớp chồng lấn nhiều.	53
2.5	Phân bố mẫu của hai lớp tách biệt tuyến tính hoàn toàn và đường phân loại LDA.	57
2.6	Ma trận nhập nhằng trong trường hợp hai lớp tách biệt hoàn toàn. . .	58
2.7	Hai đám mây chuẩn hai chiều không tương quan, có dạng tròn và được phân tách bởi đường trung trực của hai tâm.	61

Danh sách bảng

1.1	Bảng dữ liệu thống kê thô của các biến đầu vào	7
-----	--	---

Chương 1

Kiến thức chuẩn bị

1.1 Giới thiệu


1.1.1 Giới thiệu việc học thống kê

Lịch sử ngắn gọn của việc học thống kê

Thuật ngữ "Việc học thống kê" là khá mới (1980). Tuy nhiên nhiều mô hình khái niệm về nền tảng và mô hình toán học cho lĩnh vực này đã được phát triển từ lâu:

- Vào những năm 1800, Legendre và Gauss đã công bố các bài báo về phương pháp "bình phương tối thiểu" (Least-Squares Method - LS). Lý thuyết bình phương tối thiểu gắn với mô hình hồi quy tuyến tính là một trong các mô hình toán học được sử dụng phổ biến ở nhiều lĩnh vực khoa học khác nhau từ thiên văn học, hóa học, sinh học tiến hóa đến khoa học xã hội,...
- Fisher (1936) đề xuất phương pháp Phân tích tách biệt tuyến tính (Linear Discriminant Analysis - LDA) để dự đoán các biến đáp ứng định tính.
- Các nhà nghiên cứu đã đưa ra một hướng tiếp cận thay thế gọi là hồi quy Logistic (1940s).
- Đầu những năm 1970s, Nelder và Wedderburn đã đặt ra thuật ngữ các mô hình tuyến tính tổng quát hóa (Generalized Linear Models - GLM) cho toàn bộ lớp các phương pháp học thống kê bao gồm cả hồi quy tuyến tính, hồi quy logistic và các trường hợp đặc biệt (Hồi quy Poisson, Hồi quy Dirichlet).
- 1980, công nghệ máy tính được cải thiện đáng kể để các phương pháp phi tuyến có thể tính toán được (tính xấp xỉ) nhờ các công trình của Breiman, Friedman, Olshen, Stone,... (giữa 1980s) họ đã giới thiệu và phát triển các mô hình cho sự phân lớp cây hồi quy (cây Bayes).

Các phương pháp học thống kê được phân thành hai loại chính và được mô tả trong sơ đồ sau:



Hình 1.1: Sơ đồ phân loại các phương pháp học thống kê.

1.1.2 Tổng quan về việc học có giám sát

Các phương pháp học có giám sát có các thành phần chung là:


- Tập biến đầu vào (Input variables): các thuật ngữ hiện đại được sử dụng trong lĩnh vực học máy (Machine Learning - ML) | Các đặc trưng (features) trong thống kê.
- Tập biến đầu ra (Output variables): được tính toán dựa vào quy luật đặt trên tập biến đầu vào. Các biến đầu ra còn được gọi là biến đáp ứng (responses).

Một số phương pháp thuộc phạm trù học có giám sát: Hồi quy logistic, Hồi quy tuyến tính, K-NN (K lân cận gần nhất | K-Nearest Neighbors), LDA (Linear Discriminant Analysis), SVM (Support Vector Machine),...

Một số ứng dụng của phương pháp học có giám sát:

- Dự đoán dựa trên hồ sơ nhân khẩu học, chế độ ăn uống, dữ liệu lâm sàng trước đó về khả năng một người có thể mắc bệnh tim (Phạm trù y sinh).
- Dự đoán giá một số loại cổ phiếu trong khoảng t tháng từ thời điểm hiện tại dựa vào các số đo hiệu suất hoạt động của công ty và dữ liệu kinh tế liên quan (Phạm trù thị trường chứng khoán, cổ phiếu).
- Nhận dạng mẫu, chẳng hạn: nhận dạng chữ số, trong một mã nén (zipcode), chữ viết tay từ một ảnh số (Phạm trù chữ ký số, thương mại điện tử).

Ta xét bài toán học theo quan điểm là bài toán tìm mối quan hệ | sự phụ thuộc mong muốn bằng việc sử dụng một tập hữu hạn các đối tượng quan sát (|dữ liệu được quan sát)



Hình 1.2: Mô hình toán học máy học.

Mô hình chung của việc học từ ví dụ được mô tả ở hình trên như sau:

- (i) **Bộ sinh các giá trị của vectơ ngẫu nhiên** (G) (*Generator*): $\mathbf{x} \in \mathbb{R}^d$ được lấy (một cách) độc lập từ một hàm phân phối xác suất cố định nhưng không biết $F(\mathbf{x})$.
- (ii) **Bộ (| người) giám sát** (S) (*Supervisor*): (mà) trả một giá trị ra (output) y cho mỗi (vectơ) giá trị vào (input) $\mathbf{x}$, theo một phân phối điều kiện $F(y|\mathbf{x})$ cũng cố định nhưng không biết.
- (iii) **Một máy học** (LM) (*learning machine*) có khả năng thực hiện | thực thi tập các hàm $\{f(\mathbf{x}, \alpha)\}_{\alpha \in \Lambda}$, ở đây Λ là một tập các tham số.

Bài toán học là việc chọn, từ tập hợp các hàm $f(\mathbf{x}, \alpha)$ ($\alpha \in \Lambda$) đã cho, một hàm xấp xỉ tốt nhất cho đáp ứng của (bộ) giám sát. Sự lựa chọn hàm mong muốn là dựa trên một tập dữ liệu huấn luyện gồm n quan sát được lấy một cách độc lập và chung phân phối (i.i.d. – independent and identically distributed) $F(\mathbf{x}, y) = F(\mathbf{x}) \cdot F(y|\mathbf{x})$:

$$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n). \quad (1.1)$$

Trong suốt quá trình, máy học theo dõi “kiểu” mẫu từ các cặp $(\mathbf{x}, y)$ (tập dữ liệu huấn luyện | tập dữ liệu đào tạo - *the training set*). Sau quá trình đào tạo, máy phải trả về được giá trị $\hat{y}$ cho bất kỳ giá trị vào $\mathbf{x}$. Mục tiêu là giá trị $\hat{y}$ trả về “gần” (| xấp xỉ) với giá trị đáp ứng y của bộ giám sát.

Mức độ tổn thất | mức độ chênh lệch giữa đáp ứng y của bộ giám sát và đáp ứng $f(\mathbf{x}, \alpha)$ được cung cấp bởi máy học tương ứng với một giá trị vào $\mathbf{x}$ được ký hiệu là $L(y, f(\mathbf{x}, \alpha))$. Hàm $L(y, f(\mathbf{x}, \alpha))$ được gọi là **hàm tổn thất** (*the loss functional*).

Khi đó, hàm rủi ro (the risk function), ký hiệu $R(\alpha)$, chính là tổn thất trung bình xác định bởi

$$R(\alpha) = E[L(Y, f(X, \alpha))] = \int L(y, f(\mathbf{x}, \alpha)) dF(\mathbf{x}, y). \quad (1.2)$$

→ **Mục đích:** Tìm hàm $f(\mathbf{x}, \alpha_0)$ ($\alpha_0 \in \Lambda$) mà cực tiểu $R(\alpha)$ (trên lớp hàm $\{f(\mathbf{x}, \alpha)\}_{\alpha \in \Lambda}$) trong ngữ cảnh: ta không biết hàm phân phối đồng thời $F(\mathbf{x}, y)$ và chỉ có sẵn thông tin mẫu được lấy từ nó (tập dữ liệu huấn luyện (1.1)).

1.1.3 Bài toán phân loại mẫu

Trong thống kê nhiều chiều, bài toán phân loại mẫu thống kê nhằm xác định một đối tượng quan sát thuộc về lớp hay quần thể nào dựa trên các đặc trưng đo được của nó. Giả sử có tập dữ liệu

$$\mathbf{x} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$$

Trong đó mỗi mẫu $\mathbf{x}_i$ được biểu diễn bởi M biến đặc trưng. Tập dữ liệu được chia thành l lớp:

$$\mathbf{x} = \{c_1, c_2, \dots, c_l\}$$

với c_j là lớp thứ j , n_j là số mẫu thuộc lớp đó và

$$N = \sum_{j=1}^l n_j$$

Mục tiêu của bài toán phân loại là xây dựng một quy tắc quyết định để khi có một mẫu mới, ta có thể gán mẫu đó vào lớp phù hợp nhất. Trong bối cảnh học có giám sát, nhãn lớp của các mẫu huấn luyện đã biết trước, nhờ đó có thể khai thác thông tin về cấu trúc giữa các lớp để xây dựng bộ phân loại. Đây là một phương pháp giảm chiều có giám sát, trong đó nhãn lớp được sử dụng để tìm ra không gian biểu diễn mới giúp tăng khả năng tách biệt giữa các lớp.

- **Mẫu (Pattern):** Đứng ở góc độ toán học, một “mẫu” được biểu diễn như một vector đặc trưng $\mathbf{X} = \mathbf{x} \in \mathbb{R}^d$, đại diện cho các thuộc tính định lượng được trích xuất từ một đối tượng quan sát.
- **Nhận dạng (Recognition):** Là quá trình ánh xạ một mẫu $\mathbf{x}$ vào một trong các lớp (class) $\mathbf{y}$ thuộc một tập hợp rời rạc cho trước. Trong ngôn ngữ học máy, đây chính là bài toán Phân loại (Classification).
- **Nhận dạng mẫu thống kê (Statistical Pattern Recognition):** Phương pháp này xem xét sự biến thiên của các mẫu là ngẫu nhiên và giải quyết bài toán nhận dạng bằng cách tìm mối quan hệ bản chất giữa không gian đặc trưng $\mathcal{X}$ và không gian nhãn $\mathcal{Y}$ thông qua lý thuyết xác suất.

Đối với bài toán phân loại mẫu thống kê bằng hồi quy tuyến tính và hồi quy logistic, tư tưởng cốt lõi là xây dựng các hàm quyết định (hàm dự báo hoặc ranh giới phân

lớp) từ dữ liệu thực nghiệm nhằm thiết lập mối liên hệ giữa các biến đặc trưng đầu vào và nhãn lớp đầu ra. Trong khi hồi quy tuyến tính tiếp cận bài toán phân loại dưới dạng ước lượng trực tiếp giá trị của nhãn lớp bằng cách tối ưu hóa sai số bình phương trung bình, thì hồi quy logistic lại tập trung mô hình hóa xác suất có điều kiện thuộc về các lớp thông qua hàm sigmoid (logistic). Vì vậy, bài toán phân loại mẫu thống kê gắn chặt với việc tối ưu hóa các tham số để thiết lập ranh giới phân lớp tối ưu trong không gian đặc trưng.

Như đã trình bày ở phần trước, mục tiêu của quá trình học là cực tiểu hóa hàm rủi ro $R(\alpha)$. Trong bối cảnh bài toán không có chi phí phạt đặc thù cho từng loại sai sót, hàm tổn thất tự nhiên và phổ biến nhất được sử dụng là tổn thất bình phương (Squared Loss):

$$L(y, f(\mathbf{x}, \alpha)) = (y - f(\mathbf{x}, \alpha))^2$$

Khi đó, hàm rủi ro trở thành sai số bình phương trung bình (Mean Squared Error - MSE):

$$R(\alpha) = E[(Y - f(\mathbf{X}, \alpha))^2]$$

Trước khi đi tìm tham số α cụ thể, ta xét bài toán tối ưu ở mức độ tổng quát hơn: Giả sử ta không bị giới hạn bởi năng lực của máy học, tức là ta có thể tìm kiếm tự do trong một không gian toàn bộ các phiếm hàm đo được $\mathcal{F}$. Ta cần tìm phiếm hàm $\phi(x) \in \mathcal{F}$ sao cho rủi ro là nhỏ nhất:

$$\phi(x) = \arg \min_{h \in \mathcal{F}} E[(Y - h(X))^2]$$

Bằng cách thêm bớt thành phần $E(Y|X)$ — là kỳ vọng có điều kiện của đáp ứng Y từ bộ giám sát cho trước giá trị vào X — ta khai triển hàm mục tiêu:

$$\begin{aligned} E[Y - h(X)]^2 &= E[Y - E(Y|X) + E(Y|X) - h(X)]^2 \\ &= E[Y - E(Y|X)]^2 + E[E(Y|X) - h(X)]^2 \\ &\quad + 2E[(Y - E(Y|X))(E(Y|X) - h(X))] \end{aligned}$$

Trong đó,

$$E[(Y - E(Y|X))(E(Y|X) - h(X))] = E\{E[(Y - E(Y|X))(E(Y|X) - h(X)) | X]\}$$

Vì $E(Y|X)$ và $h(X)$ là các đại lượng đo được theo X , nên theo tính chất kỳ vọng

có điều kiện:

$$E \{ E [(Y - E(Y|X)) (E(Y|X) - h(X)) | X] \} = E \left\{ (E(Y|X) - h(X)) \underbrace{E [Y - E(Y|X) | X]}_{(*)} \right\}$$

Ta xét riêng thành phần (*):

$$E [Y - E(Y|X) | X] = E(Y|X) - E [E(Y|X) | X] = E(Y|X) - E(Y|X) = 0$$

Do đó,

$$R(h) = E [Y - E(Y|X)]^2 + E [E(Y|X) - h(X)]^2 \geq E [Y - E(Y|X)]^2$$

Từ đó suy ra, phép hàm xấp xỉ tốt nhất chính là:

$$\phi(\mathbf{X}) = E(Y | \mathbf{X})$$

Nói cách khác, hàm dự báo tốt nhất về mặt lý thuyết chính là kỳ vọng có điều kiện của biến đáp ứng theo nhóm biến quan trắc từ bộ giám sát.

Mặc dù đã chứng minh được kết quả tối ưu lý tưởng $\phi(\mathbf{X}) = E(Y|\mathbf{X})$, ta lại vấp phải giới hạn thực tế: ta không biết phân phối đồng thời $F(\mathbf{x}, y)$, do đó không thể xác định được dạng giải tích của $E(Y|\mathbf{X})$.

Đây chính là lúc **năng lực của máy học (Learning Machine)** được thể hiện. Thay vì mò mẫm trong không gian $\mathcal{F}$ rộng lớn, máy học thực thi bài toán bằng cách **tham số hóa** (parameterization). Ta giả định rằng tồn tại một bộ tham số tối ưu $\alpha_0 \in \Lambda$ sao cho hàm $f(\mathbf{X}, \alpha_0)$ là một xấp xỉ đủ tốt cho $\phi(\mathbf{X})$ nghĩa là

$$E(Y|X) \approx f(\mathbf{X}, \alpha_0)$$

Khi đó, bài toán học không còn là tìm một hàm ϕ trừu tượng, mà được quy về việc sử dụng tập dữ liệu huấn luyện (1.1) để ước lượng bộ tham số $\hat{\alpha} \in \Lambda$.

1.2 Mẫu từ vector đặc trưng nhiều chiều của quần thể

Như đã đề cập ở phần trên, bài toán phân loại mẫu thống kê đề cập đến mẫu ngẫu nhiên trong một quần thể. Cho điểm (vector) ngẫu nhiên d chiều $\mathbf{X} = (X_1, X_2, \dots, X_d)^T$ có hàm phân phối xác suất đồng thời $F(\mathbf{x} | \mu, \Sigma)$ không được biết rõ. Dãy các điểm

ngẫu nhiên d chiều $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ gọi là một mẫu ngẫu nhiên (đơn giản) cỡ n lấy từ điểm ngẫu nhiên $\mathbf{X}$ nếu như các $\mathbf{X}_k$ ($k = 1, 2, \dots, n$) là độc lập và có chung phân phối $F(\mathbf{x} \mid \mu, \Sigma)$ với $\mathbf{X}$. Mẫu ngẫu nhiên này có thể được biểu diễn dưới dạng ma trận dữ liệu như sau:

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1^T \\ \mathbf{X}_2^T \\ \vdots \\ \mathbf{X}_n^T \end{pmatrix} = \begin{pmatrix} X_{11} & X_{12} & \dots & X_{1d} \\ X_{21} & X_{22} & \dots & X_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{nd} \end{pmatrix}$$

ở đây $\mathbf{X}_i \in \mathbb{R}^d$, $\mathbf{X}_i = (X_{i1}, X_{i2}, \dots, X_{id})^T$, $i = 1, \dots, n$. Giá trị thể hiện hay còn gọi là giá trị được quan sát, được ghi nhận của một mẫu ngẫu nhiên sẽ được viết chữ nhỏ như thông thường, chẳng hạn:

$$\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)^T = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix}$$

để chỉ cho giá trị được quan sát hoặc ma trận dữ liệu mẫu của mẫu ngẫu nhiên này, trong đó: $\mathbf{X}_i = \mathbf{x}_i \equiv (x_{i1}, x_{i2}, \dots, x_{id})^T$ là giá trị thể hiện của $\mathbf{X}_i$ (hoặc giá trị quan sát được của $\mathbf{X}$ ở lần thứ i trong mẫu ($i = 1, 2, \dots, n$)).

Ta cũng có thể trình bày theo dạng bảng dữ liệu thống kê thô (thường sử dụng để mô tả, chẳng hạn, cho dữ liệu đầu vào của một thủ tục phân tích hồi quy) như sau:

STT	Các dấu hiệu (Các biến)			
	X_1	X_2	$\dots$	X_d
1	x_{11}	x_{12}	$\dots$	x_{1d}
2	x_{21}	x_{22}	$\dots$	x_{2d}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
i	x_{i1}	x_{i2}	$\dots$	x_{id}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_{n1}	x_{n2}	$\dots$	x_{nd}

Bảng 1.1: Bảng dữ liệu thống kê thô của các biến đầu vào

Trong đó,

- Mỗi cột đại diện cho dữ liệu quan sát một biến.
- Hàng thứ i đại diện cho giá trị thể hiện của quan sát thứ i , ký hiệu là $\mathbf{x}_i$,

($i = 1, 2, \dots, n$). Trong đó

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})^\top,$$

và x_{ij} là giá trị quan sát thứ i của biến X_j , với $j = 1, 2, \dots, d$.

1.3 Phân tích tương quan và các moment đặc trưng mẫu

Trong phân tích dữ liệu đa biến, việc nghiên cứu mối quan hệ giữa các biến và mô tả đặc trưng của mẫu đóng vai trò nền tảng. Thông qua các công cụ thống kê như trung bình và vector trung bình, ta có thể tóm tắt xu hướng phân bố của dữ liệu cũng như hỗ trợ cho các phương pháp phân tích nâng cao như phân tích tương quan hay phân lớp.

Cho $\mathbf{X} = (X_1, X_2, \dots, X_d)^T$ là một điểm ngẫu nhiên d chiều. Xét mẫu ngẫu nhiên cỡ n lấy từ $\mathbf{X}$, ký hiệu bởi $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, với $\mathbf{x}_i \in \mathbb{R}^d$. Ta quan tâm đến các moment đặc trưng sau đây.

1.3.1 Các mô-men đặc trưng mẫu

Cho $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ là mẫu thể hiện cỡ n lấy từ vector ngẫu nhiên d chiều $\mathbf{X} = (X_1, X_2, \dots, X_d)^\top$. Ta quan tâm các moment mẫu đặc trưng sau đây.

- Điểm (vector) trung bình mẫu (the sample mean vector) là vector d chiều xác định bởi

$$\bar{\mathbf{x}} \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \begin{pmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_d \end{pmatrix}, \quad (1.3)$$

trong đó:

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij} \quad (1.4)$$

là trung bình mẫu của quan sát trên biến thứ j ($j = 1, 2, \dots, d$).

- Ma trận hiệp phương sai mẫu (the sample covariance matrix): được xác định như

sau

$$S = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top = \begin{pmatrix} s_{11} & s_{12} & \dots & s_{1d} \\ s_{21} & s_{22} & \dots & s_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ s_{d1} & s_{d2} & \dots & s_{dd} \end{pmatrix}, \quad (1.5)$$

ở đây

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k) \quad (1.6)$$

là hiệp phương sai mẫu của hai biến thứ j và thứ k , và

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \quad (1.7)$$

là phương sai mẫu của biến thứ j .

1.3.2 Hệ số tương quan mẫu

Hiệp phương sai cung cấp thông tin về xu hướng biến thiên đồng thời giữa các biến ngẫu nhiên, tuy nhiên đại lượng này phụ thuộc vào thang đo của từng biến nên khó sử dụng để so sánh mức độ liên hệ giữa các cặp biến khác nhau.

Do đó, cần xây dựng một đại lượng chuẩn hóa từ hiệp phương sai, không phụ thuộc vào đơn vị đo, nhằm phản ánh chính xác mức độ và chiều hướng của mối quan hệ tuyến tính giữa các biến. Đại lượng đó chính là hệ số tương quan.

Với $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ là mẫu thể hiện cỡ n được lấy từ vector ngẫu nhiên d chiều $\mathbf{X} = (X_1, X_2, \dots, X_d)^T$, và đặt X_j^* là biến ngẫu nhiên mẫu ứng với biến X_j ($j = \overline{1, d}$), nghĩa là

$$P(X_j^* = x_{ij}) = \frac{1}{n}, \quad \forall i = 1, 2, \dots, n$$

Khi đó, hệ số tương quan mẫu giữa hai biến thứ j và thứ k (ký hiệu r_{jk}) được xác định là hệ số tương quan giữa hai biến X_j^* và X_k^*

$$\begin{aligned} r_{jk} = \rho_{X_j^*, X_k^*} &= \frac{\text{cov}(X_j^*, X_k^*)}{\sqrt{D(X_j^*)D(X_k^*)}} \\ &= \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}} = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \sqrt{\sum_{i=1}^n (x_{ik} - \bar{x}_k)^2}} \end{aligned} \quad (1.8)$$

Để thấy được ý nghĩa hình học của hệ số tương quan mẫu r_{jk} , ta xét một không gian con đặc biệt được sinh bởi vectơ toàn phần tử bằng 1. Không gian này đóng vai trò quan trọng trong việc xác định hướng chiếu và diễn giải ý nghĩa của các phép biến đổi tuyến tính.

Xét không gian vector $\mathbb{R}^n$ với tích vô hướng Euclid của hai vector $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$, $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$ được xác định bởi công thức:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^n x_i y_i.$$

Với tích vô hướng trên, độ dài (chuẩn) của một vector $\mathbf{x} \in \mathbb{R}^n$ được ký hiệu và cho bởi:

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{\sum_{i=1}^n x_i^2}.$$

Đồng thời, cosin của góc giữa hai vector $\mathbf{x}, \mathbf{y}$ cũng được xác định như sau:

$$\cos(\mathbf{x}, \mathbf{y}) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$


Và $\mathbf{x}, \mathbf{y}$ được gọi là vuông góc với nhau, ký hiệu $\mathbf{x} \perp \mathbf{y}$, nếu như

$$\cos(\mathbf{x}, \mathbf{y}) = 0 \iff \langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Khi đó, ứng với $\mathbf{1} = (1, 1, \dots, 1)^T \in \mathbb{R}^n$, không gian con sinh bởi vector này được cho bởi:

$$\langle \mathbf{1} \rangle = \{\alpha \mathbf{1} \mid \alpha \in \mathbb{R}\}.$$

Không gian $\langle \mathbf{1} \rangle$ biểu diễn đường phân giác thứ nhất hay đường phân giác chính trong hệ trục $\{e_i\}_{i=1, \dots, n}$, là hệ trục vuông góc chính tắc của $\mathbb{R}^n$. Nói cách khác, vectơ $\mathbf{1}$ tạo với các vectơ đơn vị e_i những góc bằng nhau, do đó $\langle \mathbf{1} \rangle$ chính là không gian sinh bởi vectơ chỉ phương của đường chéo chính trong $\mathbb{R}^n$. Từ cách diễn giải hình học trên, ta có thể xét phép chiếu trực giao của một vectơ bất kỳ lên không gian con $\langle \mathbf{1} \rangle$. Cụ thể, hình chiếu trực giao của vectơ x_j^* lên $\langle \mathbf{1} \rangle$, kí hiệu $\text{proj}_{\mathbf{1}} x_j^*$, với $\mathbf{x}_j^* = (x_{1j}, x_{2j}, \dots, x_{nj})^T$ được cho bởi hình sau




Hình 1.3: Hình chiếu trực giao của $\mathbf{x}_j^*$ lên $\langle \mathbf{1} \rangle$

Ta chỉ ra $\text{proj}_{\mathbf{1}} \mathbf{x}_j^* = \bar{x}_j \cdot \mathbf{1}$. Thực vậy, ta có:

$$\begin{aligned}
 \text{proj}_{\mathbf{1}} \mathbf{x}_j^* &= \|\mathbf{x}_j^*\| \cos(\mathbf{x}_j^*, \mathbf{1}) \cdot \frac{\mathbf{1}}{\|\mathbf{1}\|} \\
 &= \|\mathbf{x}_j^*\| \frac{\langle \mathbf{x}_j^*, \mathbf{1} \rangle}{\|\mathbf{x}_j^*\| \|\mathbf{1}\|} \cdot \frac{\mathbf{1}}{\|\mathbf{1}\|} \\
 &= \frac{\langle \mathbf{x}_j^*, \mathbf{1} \rangle}{\|\mathbf{1}\|^2} \cdot \mathbf{1} \\
 &= \left(\frac{1}{n} \sum_{i=1}^n x_{ij} \right) \cdot \mathbf{1} \\
 &= \bar{x}_j \cdot \mathbf{1}.
 \end{aligned}$$

Vector $d_j = \mathbf{x}_j^* - \bar{x}_j \cdot \mathbf{1}$ ($j = 1, 2, \dots, d$) được gọi là vector độ lệch của $\mathbf{x}_j^*$ đối với $\langle \mathbf{1} \rangle$.

Bước tiếp theo, với hai vector $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$, ta thực hiện phép chiếu (trực giao) của các vector này lên $\langle \mathbf{1} \rangle$. (Xem hình 1.4)



Hình 1.4: Hình chiếu trực giao của hai vector $\mathbf{x}_j^*$, $\mathbf{x}_k^*$ lên $\langle \mathbf{1} \rangle$

Đặt,

$$S_j \equiv \langle \mathbf{1}, \mathbf{x}_j^* \rangle = \{ \alpha \mathbf{1} + \beta \mathbf{x}_j^* \mid \alpha, \beta \in \mathbb{R} \};$$

$$S_k \equiv \langle \mathbf{1}, \mathbf{x}_k^* \rangle = \{ \alpha \mathbf{1} + \beta \mathbf{x}_k^* \mid \alpha, \beta \in \mathbb{R} \}$$

lần lượt là các mặt phẳng (không gian con) được sinh ra bởi vector $\mathbf{1}$ và vector $\mathbf{1}$ và một trong hai vector $\mathbf{x}_j^*$ hoặc $\mathbf{x}_k^*$. Khi đó, cosin giữa góc tạo bởi hai mặt phẳng trên được xác định như sau

$$\begin{aligned} \cos(S_j, S_k) &= \cos(\mathbf{d}_j, \mathbf{d}_k) \\ &= \frac{\langle \mathbf{d}_j, \mathbf{d}_k \rangle}{\|\mathbf{d}_j\| \|\mathbf{d}_k\|} \\ &= \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \sqrt{\sum_{i=1}^n (x_{ik} - \bar{x}_k)^2}} \\ &= r_{jk}. \end{aligned}$$


Ở đây, $\mathbf{d}_j = \mathbf{x}_j^* - \bar{x}_j \cdot \mathbf{1}$ và $\mathbf{d}_k = \mathbf{x}_k^* - \bar{x}_k \cdot \mathbf{1}$ là các vector độ lệch của $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$ đối với $\langle \mathbf{1} \rangle$. Bằng việc sử dụng bất đẳng thức Cauchy-Schwarz cho tích vô hướng, có thể thấy

$$\begin{aligned} |r_{jk}| = 1 &\iff \mathbf{d}_j = b \mathbf{d}_k \quad (b \in \mathbb{R}) \\ &\iff \mathbf{x}_j^* - \bar{x}_j \mathbf{1} = b(\mathbf{x}_k^* - \bar{x}_k \mathbf{1}) \\ &\iff \mathbf{x}_j^* = b \mathbf{x}_k^* + a \mathbf{1} \quad (a = \bar{x}_j - b \bar{x}_k). \end{aligned}$$

Tức, $\mathbf{x}_j^* \in S_k$ hay $S_j \equiv S_k$. Điều này nghĩa là có một liên hệ tuyến tính thực sự giữa hai vector $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$. Khi $r_{jk} = -1$ thì sự phụ thuộc tuyến tính của các giá trị x_{ij} và x_{ik} là nghịch biến và $r_{jk} = 1$ thì sự phụ thuộc này là đồng biến.

Ngược lại, khi $r_{jk} = 0$, tức $\mathbf{d}_k \perp \mathbf{d}_j$ (hay $S_j \perp S_k$) thì mối liên hệ tuyến tính giữa $\mathbf{d}_j$ và $\mathbf{d}_k$ là kém hiệu quả nhất. Lúc này, ta nói $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$ là không có tương quan tuyến tính với nhau.

Đồ thị đám mây điểm biểu diễn mức độ tương quan (tuyến tính) của hai vector $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$ được cho trong hình sau:



Hình 1.5: Đồ thị đám mây điểm biểu diễn mức độ tương quan của hai vector $\mathbf{x}_j^*$ và $\mathbf{x}_k^*$

1.3.3 Ma trận tương quan mẫu và hệ số tải

Từ dữ liệu thống kê cỡ n được lấy từ vector ngẫu nhiên d chiều $\mathbf{X} = (X_1, \dots, X_d)^T$, cho trong bảng 1.1, ta định nghĩa ma trận tương quan mẫu $\mathbf{r}$ ứng với bộ dữ liệu trên được xác định như sau

$$\mathbf{r} = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1d} \\ r_{21} & 1 & \cdots & r_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ r_{d1} & r_{d2} & \cdots & 1 \end{bmatrix}, \quad (1.9)$$

với r_{jk} là hệ số tương quan mẫu giữa biến thứ j và biến thứ k được cho trong 1.8 ($j, k = 1, 2, \dots, d$). Do $r_{jk} = r_{kj}$ nên ma trận $\mathbf{r}$ là đối xứng. Hơn nữa, do tính chất của tương quan mẫu, ta có $r_{jk} = r_{k,j}$ với mọi $k, j = 1, 2, \dots, d$ nên $\mathbf{r}$ là ma trận đối xứng. Lưu ý rằng, nếu đặt $\mathbf{d}_j^*$ ($j = 1, 2, \dots, d$) là vector chuẩn hóa của $\mathbf{d}_j$, nghĩa là

$$\mathbf{d}_j^* = \frac{\mathbf{d}_j}{\|\mathbf{d}_j\|},$$

thì $\|\mathbf{d}_j^*\| = 1$ và

$$\begin{aligned} r_{jk} &= \cos(\mathbf{d}_j, \mathbf{d}_k) = \frac{\langle \mathbf{d}_j, \mathbf{d}_k \rangle}{\|\mathbf{d}_j\| \|\mathbf{d}_k\|} \\ &= \left\langle \frac{\mathbf{d}_j}{\|\mathbf{d}_j\|}, \frac{\mathbf{d}_k}{\|\mathbf{d}_k\|} \right\rangle \\ &= \cos(\mathbf{d}_j^*, \mathbf{d}_k^*). \end{aligned} \quad (1.10)$$

Một điểm cần chú ý ở đây, khi áp dụng các công cụ thống kê vào thực tế, thông thường thang đo thứ nguyên của các biến X_j , ($j = 1, 2, \dots, d$) là khác nhau. Do vậy để phản ánh chính xác mối tương quan giữa biến X_j và tổng thể trên dữ liệu mẫu ta cần sử dụng đến hệ số tải (loading factor) cho X_j . Đặt,

$$\begin{aligned} F &= \mathbf{d}_1^* + \mathbf{d}_2^* + \dots + \mathbf{d}_d^* \\ &= \sum_{j=1}^d \mathbf{d}_j^* \end{aligned}$$

là vector tổng hợp lực của d vector $\mathbf{d}_j^*$. Hệ số tải ứng với biến X_j (trên dữ liệu mẫu) được cho bởi cosin của góc giữa vector $\mathbf{d}_j^*$ với vector tổng hợp lực F . Tức là, với $\theta_j = \widehat{(\mathbf{d}_j^*, F)}$:

$$\cos(\theta_j) = \cos(\mathbf{d}_j^*, F).$$

Từ ma trận tương quan mẫu được cho trong 1.9, hệ số tải ứng với biến X_j được xác định như sau:

$$\cos(\theta_j) = \frac{\text{Tổng cột | hàng } j \text{ của ma trận } \mathbf{r}}{\sqrt{\text{Tổng các số hạng của ma trận } \mathbf{r}}}.$$

Thực vậy,

$$\begin{aligned} \cos(\theta_j) &= \cos(\mathbf{d}_j^*, F) \\ &= \frac{\langle \mathbf{d}_j^*, F \rangle}{\|\mathbf{d}_j^*\| \|F\|}. \end{aligned}$$

Ta có,

$$\begin{aligned} \langle \mathbf{d}_j^*, F \rangle &= \left\langle \mathbf{d}_j^*, \sum_{k=1}^d \mathbf{d}_k^* \right\rangle \\ &= \sum_{k=1}^d \langle \mathbf{d}_j^*, \mathbf{d}_k^* \rangle \\ &= \sum_{k=1}^d r_{jk} \quad (\text{Theo } \gamma) \\ &= \text{Tổng cột | hàng } j \text{ của ma trận } \mathbf{r} \end{aligned}$$


Hơn nữa,

$$\begin{aligned}
\|F\|^2 &= \left\langle \sum_{j=1}^d d_j^*, F \right\rangle \\
&= \left\langle \sum_{j=1}^d d_j^*, \sum_{k=1}^d d_k^* \right\rangle \\
&= \sum_{j=1}^d \langle d_j^*, F \rangle \\
&= \text{Tổng các số hạng của ma trận } r.
\end{aligned}$$

Vì thế,

$$\cos(\theta_j) = \frac{\text{Tổng cột | hàng } j \text{ của ma trận } \mathbf{r}}{\sqrt{\text{Tổng các số hạng của ma trận } \mathbf{r}}}.$$

Trực quan hóa hệ số tải trong trường hợp $d = 2$ được cho bởi hình sau:



Hình 1.6: Minh họa hình học cho hệ số tải

Để minh họa cho cách xác định hệ số tải, ta xét ví dụ sau

Trường hợp $d = 3$. Xét trường hợp có ba biến X_1, X_2, X_3 . Khi đó, ta có ba vector

sai lệch chuẩn hoá:

$$d_1^*, \quad d_2^*, \quad d_3^*.$$

Gọi R là vector tổng hợp của ba vector này

$$R = d_1^* + d_2^* + d_3^*.$$

Hệ số tải của biến X_i trên vector tổng hợp R được xác định bởi cosin của góc giữa d_i^* và R

$$a_i = \cos \theta_i = \cos(d_i^*, R).$$

Theo định nghĩa cosin giữa hai vector

$$\cos \theta_i = \frac{d_i^{*T} R}{\|d_i^*\| \|R\|}.$$

Vì d_i^* đã được chuẩn hoá nên

$$\|d_i^*\| = 1.$$

Do đó

$$a_i = \cos \theta_i = \frac{d_i^{*T} R}{\|R\|}.$$

Với $R = d_1^* + d_2^* + d_3^*$, ta có

$$a_1 = \frac{1 + r_{12} + r_{13}}{\|R\|},$$

$$a_2 = \frac{r_{21} + 1 + r_{23}}{\|R\|},$$

$$a_3 = \frac{r_{31} + r_{32} + 1}{\|R\|}.$$

Như vậy, tử số của mỗi hệ số tải chính là tổng các phần tử trên hàng tương ứng của ma trận tương quan. Tổng quát, với d biến:

$$a_i = \frac{\sum_{j=1}^d r_{ij}}{\|R\|}.$$

Trong đó

$$R = \sum_{j=1}^d d_j^*.$$

Độ dài của vector tổng hợp R được xác định bởi:

$$\|R\|^2 = \sum_{i=1}^d \sum_{j=1}^d r_{ij}.$$

Do đó

$$\|R\| = \sqrt{\sum_{i=1}^d \sum_{j=1}^d r_{ij}}.$$

Suy ra công thức tổng quát của hệ số tải là:

$$a_i = \cos \theta_i = \frac{\sum_{j=1}^d r_{ij}}{\sqrt{\sum_{i=1}^d \sum_{j=1}^d r_{ij}}}$$

Áp dụng với ma trận tương quan đã cho

$$R = \begin{pmatrix} 1 & 0,9659 & 0,2588 \\ 0,9659 & 1 & 0,5000 \\ 0,2588 & 0,5000 & 1 \end{pmatrix},$$

ta có

$$r_{12} = 0,9659, \quad r_{13} = 0,2588, \quad r_{23} = 0,5000.$$

Tổng tất cả các phần tử trong ma trận tương quan là:

$$\sum_{i=1}^3 \sum_{j=1}^3 r_{ij} = 3 + 2(r_{12} + r_{13} + r_{23}).$$

Thay số

$$\sum_{i=1}^3 \sum_{j=1}^3 r_{ij} = 3 + 2(0,9659 + 0,2588 + 0,5000) = 6,4494.$$

Do đó

$$\|R\| = \sqrt{6,4494} \approx 2,5396.$$

Hệ số tải của từng biến là

$$a_1 = \frac{1 + 0,9659 + 0,2588}{\sqrt{6,4494}} = \frac{2,2247}{2,5396} \approx 0,8760,$$

$$a_2 = \frac{0,9659 + 1 + 0,5000}{\sqrt{6,4494}} = \frac{2,4659}{2,5396} \approx 0,9710,$$

$$a_3 = \frac{0,2588 + 0,5000 + 1}{\sqrt{6,4494}} = \frac{1,7588}{2,5396} \approx 0,6926.$$

Vì $a_i = \cos \theta_i$, ta có

$$\theta_1 = \arccos(0,8760) \approx 28^\circ 50' 11,23''.$$

$$\theta_2 = \arccos(0,9710) \approx 13^\circ 49' 55,98''.$$

$$\theta_3 = \arccos(0,6926) \approx 46^\circ 9' 49,41''.$$

Như vậy

$$a_2 > a_1 > a_3,$$

hay tương đương

$$\theta_2 < \theta_1 < \theta_3.$$

Điều này cho thấy biến X_2 có mức độ liên hệ mạnh nhất với trục tổng hợp R , vì hệ số tải của X_2 là lớn nhất và góc giữa d_2^* với R là nhỏ nhất. Ngược lại, X_3 có hệ số tải nhỏ nhất nên có mức độ đại diện yếu hơn cho xu hướng chung của nhóm biến.

1.4 LDA trong tiếp cận của Fisher

Trong các bài toán phân loại mẫu thống kê, đối tượng quan sát thường được biểu diễn dưới dạng một vectơ đặc trưng nhiều chiều $x \in \mathbb{R}^d$. Mỗi quan sát thuộc về một trong K lớp $c_1, c_2, \dots, c_K$, và mục tiêu của bài toán là xây dựng một quy tắc quyết định để từ một mẫu mới có thể xác định lớp của nó một cách chính xác nhất. Khi số chiều của dữ liệu lớn, việc phân loại trực tiếp trong không gian gốc thường gặp nhiều khó khăn do cấu trúc dữ liệu phức tạp, khả năng trực quan hóa hạn chế, và nguy cơ tồn tại những biến không thật sự hữu ích cho việc phân biệt lớp.

Phân tích tách biệt tuyến tính (Linear Discriminant Analysis – LDA) là một trong những phương pháp kinh điển của thống kê nhiều chiều cho cả hai mục tiêu: *giảm chiều có giám sát* và *phân loại*. Điều đáng chú ý là LDA có thể được hiểu từ hai góc nhìn khác nhau nhưng thống nhất ở kết quả cuối cùng. Góc nhìn thứ nhất là cách tiếp cận của Fisher, trong đó ta tìm một phép chiếu tuyến tính sao cho dữ liệu sau khi chiếu tách biệt lớp tốt nhất. Góc nhìn thứ hai là lý thuyết quyết định Bayes, trong đó quy tắc phân loại tối ưu được xây dựng từ xác suất hậu nghiệm; dưới giả thiết Gaussian với cùng ma trận hiệp phương sai, quy tắc Bayes dẫn đến một bộ phân loại tuyến tính. Chính sự gặp nhau của hai hướng tiếp cận này tạo nên nền tảng lý thuyết hoàn chỉnh của LDA.

Vì vậy, để hiểu đầy đủ phương pháp LDA, chương này sẽ trình bày lần lượt ba nội dung chính. Trước hết là cách tiếp cận của Fisher với tiêu chuẩn tối đa hóa sự tách biệt giữa các lớp. Tiếp theo là cơ sở của lý thuyết quyết định Bayes trong bài toán phân loại. Cuối cùng, trên nền tảng Bayes, ta chỉ ra cách mô hình Gaussian với ma trận hiệp phương sai chung dẫn trực tiếp đến LDA, đồng thời cho thấy sự tương đương giữa hướng nhìn xác suất và hướng nhìn hình học.

1.4.1 Ý tưởng hình học của Fisher

Khác với lý thuyết Bayes, Fisher không khởi đầu bằng một mô hình xác suất đầy đủ cho từng lớp. Ông xuất phát từ một câu hỏi mang tính hình học: nếu dữ liệu đã có nhãn lớp, có thể tìm được một phép chiếu tuyến tính sao cho sau khi chiếu, các lớp được tách biệt tốt nhất hay không? Trong trường hợp hai lớp, Fisher tìm một vectơ β để chiếu dữ liệu từ không gian $\mathbb{R}^d$ xuống một trục một chiều:


$$Z = \beta^T X. \quad (1.11)$$

Sau phép chiếu này, mỗi lớp sẽ có một trung bình và một mức độ phân tán riêng trên trục Z . Một hướng chiếu tốt là hướng làm khoảng cách giữa các trung bình lớp trên trục chiếu càng lớn càng tốt, đồng thời làm phương sai trong từng lớp trên trục chiếu càng nhỏ càng tốt.

Giả sử có quần thể hai lớp $l = C_1, C_2$

- Lớp C_1 với phân phối dữ liệu X_1 .
- Lớp C_2 với phân phối dữ liệu X_2 .

Mỗi quan sát $\mathbf{x} \in \mathbb{R}^d$ sao cho chiếu dữ liệu xuống một trục sao cho 'hai lớp cách xa nhau nhất' hay 'ít chồng lấn nhất'



Hình 1.7: Ý tưởng hình học của Fisher để phân tách hai lớp tốt nhất, tham khảo [4].

Nhận xét

- Khoảng cách giữa các tâm của hai lớp sau khi chiếu phải lớn nhất.
- Độ tản mát (phương sai) của dữ liệu trong nội bộ mỗi lớp sau khi chiếu phải nhỏ nhất, nghĩa là dữ liệu co cụm lại.

1.4.2 Cơ sở lý thuyết theo LDA của Fisher

1.4.2.1 Ma trận tán xạ trong lớp và giữa các lớp

Để lượng hóa hai ý tưởng “cách xa nhau nhất giữa các lớp” và “tụ lại ở trong lớp”, Fisher đưa vào hai đại lượng cơ bản.

Với mỗi lớp C_k , gọi μ_k là vectơ trung bình mẫu của lớp đó. Ma trận tán xạ trong lớp được xác định bởi

$$\Sigma_W = \sum_{k=1}^K \sum_{x_i \in C_k} (x_i - \mu_k)(x_i - \mu_k)^T. \quad (1.12)$$

Ma trận này mô tả độ phân tán của các điểm quanh trung bình lớp tương ứng. Nếu các điểm trong từng lớp tập trung lại gần nhau thì S_W nhỏ; ngược lại, nếu dữ liệu phân tán rộng thì S_W lớn.

Gọi μ là trung bình toàn cục của toàn bộ dữ liệu. Ma trận tán xạ giữa các lớp được xác định bởi

$$\Sigma_B = \sum_{k=1}^K n_k (\mu_k - \mu)(\mu_k - \mu)^T, \quad (1.13)$$

trong đó n_k là số mẫu của lớp k . Ma trận này phản ánh mức độ phân tách giữa các lớp thông qua vị trí tương đối của các trung bình lớp so với trung bình toàn cục.

1.4.3 Tiêu chuẩn Fisher trong bài toán hai lớp

Trong trường hợp hai lớp, Fisher xét biến chiếu $Z = \beta^T X$. Gọi $m_1 = \beta^T \mu_1$ và $m_2 = \beta^T \mu_2$ là trung bình của hai lớp sau chiếu. Khi đó, độ tách biệt giữa hai lớp trên trục chiếu có thể đo bằng $(m_1 - m_2)^2$. Đồng thời, phương sai trong lớp sau chiếu là

$$\Sigma_W^2 = \beta^T \Sigma_W \beta. \quad (1.14)$$

Do đó, tiêu chuẩn Fisher được viết thành

$$J(\beta) = \frac{(\beta^T (\mu_1 - \mu_2))^2}{\beta^T \Sigma_W \beta}. \quad (1.15)$$

Đây là dạng hai lớp của tiêu chuẩn tổng quát

$$J(\beta) = \frac{\beta^T \Sigma_B \beta}{\beta^T \Sigma_W \beta}. \quad (1.16)$$

Mục tiêu là tìm $\beta \neq 0$ sao cho $J(\beta)$ đạt cực đại.

1.4.4 Nghiệm tối ưu của Fisher trong trường hợp hai lớp

1.4.4.1 Tìm độ lớn bằng bài toán Rayleigh

Xét bài toán phân lớp Fisher trong trường hợp có hai lớp. Gọi μ_1, μ_2 lần lượt là vector trung bình của hai lớp. Khi đó, ma trận tán xạ giữa hai lớp được xác định bởi:

$$\Sigma_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T.$$

Ma trận tán xạ trong lớp được xác định bởi:

$$\Sigma_W = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n - 2},$$

trong đó $n = n_1 + n_2$, còn S_1, S_2 lần lượt là ma trận hiệp phương sai mẫu của hai lớp:

$$S_1 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)(x_{i1} - \mu_1)^T,$$

$$S_2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)(x_{i2} - \mu_2)^T.$$

Tiêu chuẩn Fisher được viết dưới dạng:

$$J(\beta) = \frac{\beta^T \Sigma_B \beta}{\beta^T \Sigma_W \beta}, \quad \beta \in \mathbb{R}^d.$$

Mục tiêu là tìm vector chiều β sao cho $J(\beta)$ đạt giá trị lớn nhất:

$$\max_{\beta \neq 0} J(\beta) = \max_{\beta \neq 0} \frac{\beta^T \Sigma_B \beta}{\beta^T \Sigma_W \beta}.$$

Vì Σ_W là ma trận đối xứng xác định dương nên tồn tại phân rã phổ:

$$\Sigma_W = D \Lambda D^T,$$

trong đó D là ma trận trực giao chứa các vector riêng của Σ_W , còn Λ là ma trận đường chéo chứa các giá trị riêng dương:

$$D^T D = I, \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d),$$

với,

$$\lambda_1, \lambda_2, \dots, \lambda_d > 0.$$

Do đó,

$$\Sigma_W^{1/2} = D\Lambda^{1/2}D^T,$$

trong đó,

$$\Lambda^{1/2} = \text{diag}\left(\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_d}\right).$$

Tương tự,

$$\Sigma_W^{-1/2} = D\Lambda^{-1/2}D^T,$$

với,

$$\Lambda^{-1/2} = \text{diag}\left(\frac{1}{\sqrt{\lambda_1}}, \frac{1}{\sqrt{\lambda_2}}, \dots, \frac{1}{\sqrt{\lambda_d}}\right).$$

Đặt,

$$y = \Sigma_W^{1/2}\beta.$$

Suy ra,

$$\beta = \Sigma_W^{-1/2}y.$$

Thay vào tiêu chuẩn Fisher, ta được

$$J(\beta) = \frac{\beta^T \Sigma_B \beta}{\beta^T \Sigma_W \beta}.$$

Xét mẫu số trước,

$$\beta^T \Sigma_W \beta = \left(\Sigma_W^{-1/2}y\right)^T \Sigma_W \left(\Sigma_W^{-1/2}y\right).$$

Vì $\Sigma_W^{-1/2}$ đối xứng nên

$$\beta^T \Sigma_W \beta = y^T \Sigma_W^{-1/2} \Sigma_W \Sigma_W^{-1/2} y.$$

Mà,

$$\Sigma_W^{-1/2} \Sigma_W \Sigma_W^{-1/2} = I,$$

nên,

$$\beta^T \Sigma_W \beta = y^T y.$$

Tương tự, tử số trở thành

$$\beta^T \Sigma_B \beta = \left(\Sigma_W^{-1/2} y \right)^T \Sigma_B \left(\Sigma_W^{-1/2} y \right).$$

Do đó,

$$\beta^T \Sigma_B \beta = y^T \left(\Sigma_W^{-1/2} \right)^T \Sigma_B \Sigma_W^{-1/2} y.$$

Vì $\Sigma_W^{-1/2}$ đối xứng nên

$$\left(\Sigma_W^{-1/2} \right)^T = \Sigma_W^{-1/2}.$$

Đặt,

$$S = \left(\Sigma_W^{-1/2} \right)^T \Sigma_B \Sigma_W^{-1/2} = \Sigma_W^{-1/2} \Sigma_B \Sigma_W^{-1/2}.$$

Khi đó, tiêu chuẩn Fisher trở thành

$$J(\beta) = \frac{y^T S y}{y^T y}.$$

Vì Σ_B đối xứng và $\Sigma_W^{-1/2}$ đối xứng nên S cũng là ma trận đối xứng

$$S^T = S.$$

Do đó, bài toán tối ưu Fisher được đưa về bài toán

$$\max_{y \neq 0} \frac{y^T S y}{y^T y}.$$

Đây chính là bài toán thương Rayleigh.

Đặt

$$x = \frac{y}{\|y\|}, \quad \|x\| = 1.$$

Khi đó,

$$\frac{y^T S y}{y^T y} = x^T S x.$$

Vì S là ma trận đối xứng nên tồn tại phân rã phổ

$$S = U\Gamma U^T,$$

trong đó,

$$U^T U = I,$$

và,

$$\Gamma = \text{diag}(\gamma_1, \gamma_2, \dots, \gamma_d),$$

với,

$$\gamma_1 \geq \gamma_2 \geq \dots \geq \gamma_d.$$

Đặt,

$$z = U^T x.$$

Ta có,

$$\|z\|^2 = z^T z = x^T U U^T x = x^T x = 1.$$

Mặt khác,

$$x^T S x = x^T U \Gamma U^T x = z^T \Gamma z.$$

Suy ra,

$$x^T S x = \gamma_1 z_1^2 + \gamma_2 z_2^2 + \dots + \gamma_d z_d^2.$$

Vì,

$$\gamma_1 \geq \gamma_2 \geq \dots \geq \gamma_d,$$

nên,

$$x^T S x \leq \gamma_1 (z_1^2 + z_2^2 + \dots + z_d^2).$$

Do,

$$z_1^2 + z_2^2 + \dots + z_d^2 = \|z\|^2 = 1,$$

nên,

$$x^T S x \leq \gamma_1.$$

Dấu bằng xảy ra khi x là vector riêng ứng với giá trị riêng lớn nhất γ_1 của ma trận S . Do đó,

$$x_{\text{opt}} = u_1,$$

trong đó u_1 là vector riêng ứng với giá trị riêng lớn nhất của S .

Vì,

$$x = \frac{y}{\|y\|},$$

nên,

$$y_{\text{opt}} \propto u_1.$$

Mặt khác,

$$y = \Sigma_W^{1/2} \beta.$$

Suy ra,

$$\Sigma_W^{1/2} \beta_{\text{opt}} \propto u_1.$$

Do đó,

$$\beta_{\text{opt}} \propto \Sigma_W^{-1/2} u_1.$$

Trong trường hợp hai lớp, ma trận tán xạ giữa lớp có dạng

$$\Sigma_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T.$$

Khi đó, nghiệm tối ưu của Fisher có dạng quen thuộc

$$\boxed{\beta_{\text{opt}} \propto \Sigma_W^{-1}(\mu_1 - \mu_2)}$$

hay có thể viết,

$$\boxed{\beta_{\text{opt}} = c \Sigma_W^{-1}(\mu_1 - \mu_2), \quad c \neq 0.}$$

Do tiêu chuẩn Fisher không thay đổi khi nhân β với một hằng số khác 0, nên ta

thường chọn

$$\boxed{\beta_{\text{opt}} = \Sigma_W^{-1}(\mu_1 - \mu_2).}$$

Như vậy, trong trường hợp hai lớp, nghiệm tối ưu của Fisher là vector chiếu theo hướng nghịch đảo ma trận tán xạ trong lớp nhân với hiệu vector trung bình của hai lớp.

1.4.4.2 Tìm phương tối ưu bằng bất đẳng thức Cauchy–Schwarz

Ngoài cách suy ra nghiệm tối ưu bằng bài toán Rayleigh, ta cũng có thể tìm phương tối ưu của Fisher bằng bất đẳng thức Cauchy–Schwarz.

Trong trường hợp hai lớp, tiêu chuẩn Fisher có dạng:

$$J(\beta) = \frac{\beta^T \Sigma_B \beta}{\beta^T \Sigma_W \beta}.$$

Với,

$$\Sigma_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T.$$

Đặt,

$$d = \mu_1 - \mu_2.$$

Khi đó,

$$\Sigma_B = dd^T.$$

Suy ra,

$$\beta^T \Sigma_B \beta = \beta^T dd^T \beta = (\beta^T d)^2.$$

Do đó, tiêu chuẩn Fisher trở thành:

$$J(\beta) = \frac{(\beta^T d)^2}{\beta^T \Sigma_W \beta}.$$

Vì Σ_W là ma trận đối xứng xác định dương nên tồn tại $\Sigma_W^{1/2}$ và $\Sigma_W^{-1/2}$. Ta đặt,

$$x = \Sigma_W^{1/2} \beta,$$

và,

$$y = \Sigma_W^{-1/2} d.$$

Khi đó,

$$x^T y = \left(\Sigma_W^{1/2} \beta \right)^T \left(\Sigma_W^{-1/2} d \right).$$

Vì $\Sigma_W^{1/2}$ và $\Sigma_W^{-1/2}$ đối xứng, đồng thời

$$\Sigma_W^{1/2} \Sigma_W^{-1/2} = I,$$

nên,

$$x^T y = \beta^T \Sigma_W^{1/2} \Sigma_W^{-1/2} d = \beta^T d.$$

Mặt khác,

$$x^T x = \left(\Sigma_W^{1/2} \beta \right)^T \left(\Sigma_W^{1/2} \beta \right) = \beta^T \Sigma_W \beta.$$

Và,

$$y^T y = \left(\Sigma_W^{-1/2} d \right)^T \left(\Sigma_W^{-1/2} d \right) = d^T \Sigma_W^{-1} d.$$

Do đó,

$$J(\beta) = \frac{(\beta^T d)^2}{\beta^T \Sigma_W \beta} = \frac{(x^T y)^2}{x^T x}.$$

Áp dụng bất đẳng thức Cauchy–Schwarz

$$(x^T y)^2 \leq (x^T x)(y^T y).$$

Suy ra,

$$\frac{(x^T y)^2}{x^T x} \leq y^T y.$$

Vì vậy,

$$J(\beta) \leq d^T \Sigma_W^{-1} d.$$

Hay,

$$\boxed{J(\beta) \leq d^T \Sigma_W^{-1} d}$$

Dấu bằng trong bất đẳng thức Cauchy–Schwarz xảy ra khi và chỉ khi x và y cùng phương, tức là tồn tại hằng số $c \neq 0$ sao cho

$$x = cy.$$

Thay lại x và y , ta có,

$$\Sigma_W^{1/2} \beta = c \Sigma_W^{-1/2} d.$$

Nhân hai vế với $\Sigma_W^{-1/2}$, ta được,

$$\Sigma_W^{-1/2} \Sigma_W^{1/2} \beta = c \Sigma_W^{-1/2} \Sigma_W^{-1/2} d.$$

Suy ra,

$$\beta = c \Sigma_W^{-1} d.$$

Vì,

$$d = \mu_1 - \mu_2,$$

nên,

$$\beta = c \Sigma_W^{-1} (\mu_1 - \mu_2).$$

Trong bài toán phân lớp, điều quan trọng là phương của vector β , còn độ lớn của β không làm thay đổi tỷ lệ trong tiêu chuẩn Fisher. Do đó, ta có thể chọn $c = 1$ và thu được nghiệm tối ưu

$$\boxed{\beta_{\text{opt}} = \Sigma_W^{-1} (\mu_1 - \mu_2)}$$

Như vậy, bằng bất đẳng thức Cauchy–Schwarz, ta cũng suy ra được rằng phương chiếu tối ưu của Fisher trong trường hợp hai lớp là phương của vector

$$\Sigma_W^{-1} (\mu_1 - \mu_2).$$

1.5 Lý thuyết quyết định Bayes trong bài toán phân loại

1.5.1 Xác suất hậu nghiệm và quy tắc Bayes tối ưu

Trong lý thuyết quyết định thống kê, một quy tắc phân loại được xem là tối ưu nếu nó làm cực tiểu hóa rủi ro kỳ vọng. Trong trường hợp đơn giản nhất, khi chi phí phân loại đúng bằng 0 và chi phí phân loại sai bằng 1, bài toán tối ưu tương đương với việc cực tiểu hóa xác suất sai phân loại. Khi đó, quy tắc Bayes cho biết: với một quan sát x , ta nên gán x vào lớp có xác suất hậu nghiệm lớn nhất. Nếu ký hiệu G là biến ngẫu nhiên chỉ lớp, thì quy tắc này có dạng

$$G(x) = \arg \max_k P(G = k \mid X = x). \quad (1.17)$$

Theo công thức Bayes,

$$P(G = k \mid X = x) = \frac{f_k(x)\pi_k}{\sum_{\ell=1}^K f_{\ell}(x)\pi_{\ell}}, \quad (1.18)$$

trong đó $f_k(x) = p(x \mid G = k)$ là mật độ có điều kiện của X trong lớp k , còn $\pi_k = P(G = k)$ là xác suất tiên nghiệm của lớp đó. Vì mẫu số là như nhau cho mọi lớp khi so sánh, quy tắc Bayes tối ưu có thể viết gọn thành

$$G(x) = \arg \max_k \{f_k(x)\pi_k\}. \quad (1.19)$$

Điều này cho thấy, nếu biết đầy đủ các mật độ lớp và các xác suất tiên nghiệm, thì bài toán phân loại về nguyên tắc đã được giải quyết.

1.5.2 Mô hình Gaussian cho các lớp

Để biến quy tắc Bayes thành một bộ phân loại cụ thể, cần giả thiết dạng của các mật độ lớp. Một giả thiết quan trọng trong thống kê nhiều chiều là mỗi lớp tuân theo phân phối chuẩn nhiều chiều. Cụ thể, với lớp c_k , ta giả sử

$$X \mid G = k \sim N_p(\mu_k, \Sigma_k), \quad (1.20)$$

trong đó μ_k là vectơ trung bình và Σ_k là ma trận hiệp phương sai của lớp k . Khi đó, mật độ lớp có dạng

$$f_k(x) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) \right\}. \quad (1.21)$$

Thay biểu thức này vào quy tắc Bayes và lấy logarit, ta thu được các hàm phân biệt

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \log \pi_k, \quad (1.22)$$

bỏ qua các hằng số chung không phụ thuộc vào k . Khi đó, quy tắc phân loại Bayes trở thành

$$G(x) = \arg \max_k \delta_k(x). \quad (1.23)$$

Nếu các Σ_k khác nhau giữa các lớp, biên quyết định giữa hai lớp nói chung là bậc hai, và bộ phân loại nhận được là Quadratic Discriminant Analysis (QDA).

1.6 LDA trong cách tiếp cận của lý thuyết quyết định Bayes

1.6.1 Trường hợp cùng hiệp phương sai và sự xuất hiện của biên tuyến tính

LDA xuất hiện như một trường hợp riêng có ý nghĩa đặc biệt của mô hình Gaussian ở trên, khi giả sử tất cả các lớp có chung một ma trận hiệp phương sai:

$$\Sigma_1 = \Sigma_2 = \dots = \Sigma_K = \Sigma. \quad (1.24)$$

Trong trường hợp này, các hàm phân biệt được rút gọn thành

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k. \quad (1.25)$$

Công thức này cho thấy $\delta_k(x)$ là một hàm tuyến tính theo x . Do đó, biên quyết định giữa hai lớp bất kỳ k và ℓ , xác định bởi điều kiện $\delta_k(x) = \delta_\ell(x)$, có dạng

$$x^T \Sigma^{-1} (\mu_k - \mu_\ell) - \frac{1}{2} (\mu_k^T \Sigma^{-1} \mu_k - \mu_\ell^T \Sigma^{-1} \mu_\ell) + \log \frac{\pi_k}{\pi_\ell} = 0. \quad (1.26)$$

Đây là phương trình của một siêu phẳng trong không gian $\mathbb{R}^d$. Như vậy, dưới giả thiết Gaussian nhiều chiều với cùng ma trận hiệp phương sai, quy tắc Bayes tối ưu cho

phân loại là tuyến tính.

Trong trường hợp hai lớp c_1 và c_2 , nếu đặt

$$a = \Sigma^{-1}(\mu_1 - \mu_2) \quad (1.27)$$

và

$$b = -\frac{1}{2}(\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2) + \log \frac{\pi_1}{\pi_2}, \quad (1.28)$$

thì biên quyết định có dạng

$$a^T x + b = 0. \quad (1.29)$$

1.6.2 Quy tắc phân loại LDA trong thực hành

Trong thực tế, các tham số quần thể π_k, μ_k, Σ không biết trước và phải được ước lượng từ dữ liệu huấn luyện. Gọi N là tổng số mẫu, N_k là số mẫu thuộc lớp k . Các ước lượng tự nhiên được dùng trong LDA là

$$\hat{\pi}_k = \frac{N_k}{N}, \quad \hat{\mu}_k = \frac{1}{N_k} \sum_{g_i=k} x_i, \quad (1.30)$$

và ma trận hiệp phương sai mẫu gộp

$$\hat{\Sigma} = \frac{1}{N - K} \sum_{k=1}^K \sum_{g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T. \quad (1.31)$$

Từ đó, các hàm phân biệt ước lượng có dạng

$$\hat{\delta}_k(x) = x^T \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^T \hat{\Sigma}^{-1} \hat{\mu}_k + \log \hat{\pi}_k, \quad (1.32)$$

và quy tắc phân loại là

$$\hat{G}(x) = \arg \max_k \hat{\delta}_k(x). \quad (1.33)$$

Trong bài toán hai lớp, điều này tương đương với việc kiểm tra dấu của hiệu $\hat{\delta}_1(x) - \hat{\delta}_2(x)$.

1.6.3 Sự tương đương giữa Fisher và LDA theo Bayes

Đến đây có thể thấy rằng hai cách tiếp cận tưởng như khác nhau thực ra dẫn đến cùng một cấu trúc toán học. Theo quyết định Bayes, dưới giả thiết Gaussian có cùng hiệp phương sai, hướng quyết định giữa hai lớp phụ thuộc vào vectơ

$$\Sigma^{-1}(\mu_1 - \mu_2). \quad (1.34)$$

Theo Fisher, hướng chiếu tối ưu cho hai lớp là

$$S_W^{-1}(\mu_1 - \mu_2). \quad (1.35)$$

Trong mô hình Gaussian với cùng hiệp phương sai, S_W chỉ là ước lượng mẫu của cấu trúc phân tán trong lớp, còn Σ là ma trận hiệp phương sai quần thể. Vì vậy, hai vectơ trên là cùng phương. Nói cách khác, hướng chiếu tối ưu của Fisher chính là hướng pháp tuyến của siêu phẳng Bayes trong trường hợp Gaussian đồng hiệp phương sai. Đây là kết luận nền tảng cho sự thống nhất giữa hai cách hiểu của LDA.

1.6.4 Minh họa phân loại một chiều trên bộ dữ liệu Iris

Để minh họa cụ thể quy tắc phân loại tuyến tính trong trường hợp một chiều, ta xét bộ dữ liệu Iris của Fisher. Bộ dữ liệu này gồm ba loài hoa Iris là *setosa*, *versicolor* và *virginica*, với bốn thuộc tính đo lường hình thái học: chiều dài đài hoa, chiều rộng đài hoa, chiều dài cánh hoa và chiều rộng cánh hoa.

Trong ví dụ này, ta chỉ xét hai lớp hoa:

$$C_0 = \textit{versicolor}, \quad C_1 = \textit{virginica},$$

và chỉ sử dụng một thuộc tính duy nhất là chiều dài cánh hoa, ký hiệu bởi

$$x = \text{Petal.Length}.$$

Như vậy, bài toán phân loại nhiều chiều ban đầu được rút gọn thành bài toán phân loại một chiều trên thực.

Gọi X_0 là tập các quan sát thuộc lớp *versicolor* và X_1 là tập các quan sát thuộc lớp *virginica*. Từ dữ liệu Iris, ta có

$$n_0 = n_1 = 50,$$

do đó xác suất tiên nghiệm của hai lớp là

$$\hat{\pi}_0 = \hat{\pi}_1 = \frac{1}{2}.$$

Trung bình mẫu của thuộc tính *Petal.Length* trong hai lớp lần lượt là

$$\hat{\mu}_0 = 4.260, \quad \hat{\mu}_1 = 5.552.$$

Phương sai mẫu của hai lớp là

$$s_0^2 = 0.2208, \quad s_1^2 = 0.3046.$$

Vì LDA giả thiết hai lớp có chung phương sai trong trường hợp một chiều, phương sai gộp được ước lượng bởi

$$s_p^2 = \frac{(n_0 - 1)s_0^2 + (n_1 - 1)s_1^2}{n_0 + n_1 - 2}.$$

Thay số vào ta được

$$s_p^2 = \frac{49(0.2208) + 49(0.3046)}{98} \approx 0.2627.$$

Trong trường hợp một chiều, hàm phân biệt LDA của lớp k có dạng

$$\hat{\delta}_k(x) = x \frac{\hat{\mu}_k}{s_p^2} - \frac{1}{2} \frac{\hat{\mu}_k^2}{s_p^2} + \log \hat{\pi}_k, \quad k = 0, 1.$$

Biên quyết định giữa hai lớp được xác định bởi điều kiện

$$\hat{\delta}_0(x) = \hat{\delta}_1(x).$$

Giải phương trình này theo x , ta thu được ngưỡng phân loại

$$x_{\text{bnd}} = \frac{\hat{\mu}_0 + \hat{\mu}_1}{2} - \frac{s_p^2}{\hat{\mu}_1 - \hat{\mu}_0} \log \frac{\hat{\pi}_1}{\hat{\pi}_0}.$$

Trong ví dụ này, do hai lớp có cùng số quan sát nên

$$\hat{\pi}_0 = \hat{\pi}_1,$$

suy ra

$$\log \frac{\hat{\pi}_1}{\hat{\pi}_0} = 0.$$

Vì vậy, ngưỡng phân loại trở thành trung điểm giữa hai trung bình:

$$x_{\text{bnd}} = \frac{\hat{\mu}_0 + \hat{\mu}_1}{2} = \frac{4.260 + 5.552}{2} = 4.906.$$


Do $\hat{\mu}_1 > \hat{\mu}_0$, quy tắc phân loại LDA trong trường hợp này là

$$\hat{G}(x) = \begin{cases} C_0, & x \leq 4.906, \\ C_1, & x > 4.906. \end{cases}$$

Hay viết cụ thể theo tên loài hoa:

$$\hat{G}(x) = \begin{cases} \text{versicolor}, & \text{nếu Petal.Length} \leq 4.906, \\ \text{virginica}, & \text{nếu Petal.Length} > 4.906. \end{cases}$$

Hình 1.8 biểu diễn hai mật độ Gaussian một chiều được ước lượng từ dữ liệu của hai lớp *versicolor* và *virginica*. Hai đường cong được vẽ dưới dạng $\hat{\pi}_k f_k(x)$, tức là mật độ có nhân với xác suất tiên nghiệm của lớp tương ứng. Đường thẳng đứng nét đứt màu đen biểu diễn ngưỡng phân loại LDA tại $x_{\text{bnd}} = 4.906$.



Hình 1.8: Minh họa phân loại một chiều bằng LDA trên bộ dữ liệu Iris với hai lớp *versicolor* và *virginica* theo thuộc tính *Petal.Length*.

Từ hình minh họa có thể thấy phân phối của lớp *versicolor* tập trung chủ yếu về phía bên trái, trong khi phân phối của lớp *virginica* tập trung về phía bên phải. Tuy nhiên, hai phân phối vẫn có một vùng chồng lấn xung quanh ngưỡng phân loại. Đây chính là vùng mà khả năng phân loại sai có thể xảy ra.

Kết quả phân loại trên 100 quan sát thuộc hai lớp cho ma trận lỗi như sau:

	versicolor	virginica
Dự đoán versicolor	48	6
Dự đoán virginica	2	44

Do đó, số quan sát bị phân loại sai là

$$2 + 6 = 8.$$

Tỷ lệ phân loại sai là

$$\frac{8}{100} = 0.08.$$

Như vậy, trong ví dụ một chiều này, bộ phân loại LDA đạt tỷ lệ lỗi xấp xỉ 8%. Ví dụ trên cho thấy khi giả thiết hai lớp có phân phối Gaussian với cùng phương sai, biên quyết định LDA trong không gian một chiều chỉ là một điểm cắt trên trục số. Các quan sát nằm về một phía của điểm cắt được gán vào lớp thứ nhất, còn các quan sát nằm về phía còn lại được gán vào lớp thứ hai. Đây là dạng đơn giản nhất của biên tuyến tính trong LDA.

Ở ví dụ trước, hai lớp *versicolor* và *virginica* có vùng giao nhau nên LDA vẫn có thể phát sinh lỗi phân loại. Để minh họa trường hợp biên quyết định một chiều có thể phân tách hoàn toàn dữ liệu, ta xét một cặp hoa khác trong bộ dữ liệu Iris, đó là *setosa* và *versicolor*, với thuộc tính phân loại là *Petal.Length*.

Gọi

$$C_0 = \textit{setosa}, \quad C_1 = \textit{versicolor},$$

và

$$x = \textit{Petal.Length}.$$

Khi đó, mỗi quan sát được biểu diễn bởi một giá trị thực trên trục một chiều.

Từ bộ dữ liệu Iris, mỗi lớp có 50 quan sát, do đó:

$$n_0 = n_1 = 50.$$

Suy ra xác suất tiên nghiệm của hai lớp là:

$$\hat{\pi}_0 = \hat{\pi}_1 = \frac{1}{2}.$$

Trung bình mẫu của thuộc tính *Petal.Length* trong hai lớp lần lượt là:

$$\hat{\mu}_0 = 1.462, \quad \hat{\mu}_1 = 4.260.$$

Trong đó, $\hat{\mu}_0$ là trung bình của lớp *setosa*, còn $\hat{\mu}_1$ là trung bình của lớp *versicolor*. Phương sai mẫu tương ứng là:

$$s_0^2 = 0.0302, \quad s_1^2 = 0.2208.$$

Vì LDA giả thiết hai lớp có cùng phương sai trong trường hợp một chiều, phương sai gộp được tính bởi:

$$s_p^2 = \frac{(n_0 - 1)s_0^2 + (n_1 - 1)s_1^2}{n_0 + n_1 - 2}.$$

Thay số vào ta được:

$$s_p^2 = \frac{49(0.0302) + 49(0.2208)}{98} \approx 0.1255.$$

Trong trường hợp một chiều, hàm phân biệt LDA của lớp k có dạng:

$$\hat{\delta}_k(x) = x \frac{\hat{\mu}_k}{s_p^2} - \frac{1}{2} \frac{\hat{\mu}_k^2}{s_p^2} + \log \hat{\pi}_k, \quad k = 0, 1.$$

Biên quyết định giữa hai lớp được xác định bởi điều kiện:

$$\hat{\delta}_0(x) = \hat{\delta}_1(x).$$

Giải phương trình trên theo x , ta thu được ngưỡng phân loại:

$$x_{\text{bnd}} = \frac{\hat{\mu}_0 + \hat{\mu}_1}{2} - \frac{s_p^2}{\hat{\mu}_1 - \hat{\mu}_0} \log \frac{\hat{\pi}_1}{\hat{\pi}_0}.$$

Do hai lớp có cùng số quan sát nên:

$$\hat{\pi}_0 = \hat{\pi}_1,$$

suy ra:

$$\log \frac{\hat{\pi}_1}{\hat{\pi}_0} = 0.$$

Vì vậy, ngưỡng phân loại trở thành:

$$x_{\text{bnd}} = \frac{\hat{\mu}_0 + \hat{\mu}_1}{2} = \frac{1.462 + 4.260}{2} \approx 2.861.$$

Mặt khác, trong dữ liệu thực tế, giá trị lớn nhất của *Petal.Length* đối với lớp *setosa* là:

$$\max(\textit{setosa}) = 1.9,$$

trong khi giá trị nhỏ nhất của *Petal.Length* đối với lớp *versicolor* là:

$$\min(\textit{versicolor}) = 3.0.$$

Do đó:

$$1.9 < 3.0.$$

Điều này cho thấy hai lớp *setosa* và *versicolor* được tách biệt hoàn toàn theo thuộc tính *Petal.Length*. Khoảng trống giữa hai lớp là:

$$(1.9, 3.0).$$

Ngưỡng LDA:


$$x_{\text{bnd}} \approx 2.861$$

nằm trong khoảng trống này, nên có thể phân loại đúng toàn bộ các quan sát thuộc hai lớp.

Do $\hat{\mu}_1 > \hat{\mu}_0$, quy tắc phân loại LDA trong ví dụ này là:

$$\hat{G}(x) = \begin{cases} \textit{setosa}, & \text{nếu } \textit{Petal.Length} \leq 2.861, \\ \textit{versicolor}, & \text{nếu } \textit{Petal.Length} > 2.861. \end{cases}$$

Hình 1.9 minh họa hai phân phối một chiều của hai lớp *setosa* và *versicolor* theo thuộc tính *Petal.Length*. Đường thẳng đứng nét đứt màu đen biểu diễn ngưỡng phân loại LDA. Các điểm dữ liệu thực tế của hai lớp nằm ở hai phía khác nhau của ngưỡng, cho thấy sự tách biệt hoàn toàn trong trường hợp này.



Hình 1.9: Minh họa phân loại một chiều bằng LDA trên bộ dữ liệu Iris với hai lớp *setosa* và *versicolor* theo thuộc tính *Petal.Length*.

Kết quả phân loại trên 100 quan sát thuộc hai lớp *setosa* và *versicolor* cho ma trận nhầm lẫn:

	<i>setosa</i>	<i>versicolor</i>
Dự đoán <i>setosa</i>	50	0
Dự đoán <i>versicolor</i>	0	50

Từ ma trận trên, không có quan sát nào bị phân loại sai. Do đó, tỷ lệ lỗi phân loại là:

$$\frac{0}{100} = 0.$$

Ví dụ này cho thấy trong trường hợp một chiều, nếu hai lớp có sự tách biệt rõ ràng trên một thuộc tính, biên quyết định của LDA chỉ là một điểm cắt trên trục số và có thể phân loại hoàn toàn chính xác các quan sát trong dữ liệu. Trường hợp *setosa* và *versicolor* với thuộc tính *Petal.Length* là một minh họa điển hình cho khả năng phân tách tuyến tính của LDA trong không gian một chiều.

1.7 Xác định độ chính xác phân loại mẫu thống kê

Trong phạm vi đề án này, ta chỉ xét trường hợp hàm tổn thất $0 - 1$. Điều này có nghĩa là nếu một quan sát được phân loại đúng thì chi phí phân loại bằng 0, còn nếu quan sát đó bị phân loại sai thì chi phí phân loại bằng 1, bất kể sai từ lớp C_1 sang C_2 hay từ lớp C_2 sang C_1 .

Cụ thể:

$$c(1|1) = 0, \quad c(2|2) = 0,$$

và:

$$c(2|1) = 1, \quad c(1|2) = 1.$$

Trong đó:

- $c(1|1)$ là chi phí khi quan sát thực sự thuộc lớp C_1 và được phân loại đúng vào lớp C_1 ;
- $c(2|2)$ là chi phí khi quan sát thực sự thuộc lớp C_2 và được phân loại đúng vào lớp C_2 ;
- $c(2|1)$ là chi phí khi quan sát thực sự thuộc lớp C_1 nhưng bị phân loại sai vào lớp C_2 ;

- $c(1|2)$ là chi phí khi quan sát thực sự thuộc lớp C_2 nhưng bị phân loại sai vào lớp C_1 .

Với giả định hàm tổn thất $0 - 1$, chi phí phân loại sai kỳ vọng ECM sẽ trùng với xác suất phân loại sai tổng cộng TPM. Do đó, trong phần này, việc đánh giá độ chính xác phân loại được thực hiện thông qua ma trận nhập nhằng, tỷ lệ phân loại đúng, TPM và ECM.

1.7.1 Ma trận nhập nhằng

Xét bài toán phân loại hai lớp:

$$C_1, \quad C_2.$$

Một quan sát mới x có thể thuộc về một trong hai lớp này. Sau khi áp dụng quy tắc phân loại, x sẽ được gán vào một trong hai lớp C_1 hoặc C_2 .

Khi đó, có bốn khả năng xảy ra:

- Quan sát thực sự thuộc lớp C_1 và được phân loại đúng vào C_1 ;
- Quan sát thực sự thuộc lớp C_1 nhưng bị phân loại sai vào C_2 ;
- Quan sát thực sự thuộc lớp C_2 và được phân loại đúng vào C_2 ;
- Quan sát thực sự thuộc lớp C_2 nhưng bị phân loại sai vào C_1 .

Các khả năng này được tổng hợp trong ma trận nhầm lẫn, hay còn gọi là *confusion matrix*:

Thực tế / Dự đoán	$\hat{C}_1$	$\hat{C}_2$	Tổng
C_1	n_{11}	n_{12}	$n_{1.}$
C_2	n_{21}	n_{22}	$n_{2.}$
Tổng	$n_{.1}$	$n_{.2}$	n

Trong đó:

- n_{11} là số quan sát thực sự thuộc lớp C_1 và được phân loại đúng vào C_1 ;
- n_{12} là số quan sát thực sự thuộc lớp C_1 nhưng bị phân loại sai vào C_2 ;
- n_{21} là số quan sát thực sự thuộc lớp C_2 nhưng bị phân loại sai vào C_1 ;
- n_{22} là số quan sát thực sự thuộc lớp C_2 và được phân loại đúng vào C_2 .

Tổng số quan sát thuộc lớp C_1 là:

$$n_{1.} = n_{11} + n_{12}.$$

Tổng số quan sát thuộc lớp C_2 là:

$$n_{2.} = n_{21} + n_{22}.$$

Tổng số quan sát trong mẫu là:

$$n = n_{11} + n_{12} + n_{21} + n_{22}.$$

Số quan sát được phân loại đúng là:

$$n_{11} + n_{22}.$$

Số quan sát bị phân loại sai là:

$$n_{12} + n_{21}.$$

Do đó, độ chính xác phân loại được xác định bởi:

$$\text{Accuracy} = \frac{n_{11} + n_{22}}{n}.$$

Tỷ lệ phân loại sai được xác định bởi:

$$\text{Error Rate} = \frac{n_{12} + n_{21}}{n}.$$

Vì mỗi quan sát hoặc được phân loại đúng hoặc bị phân loại sai, nên:

$$\text{Accuracy} + \text{Error Rate} = 1.$$

Hay:

$$\text{Accuracy} = 1 - \text{Error Rate}.$$

1.7.2 TPM – Total Probability of Misclassification

TPM, viết đầy đủ là *Total Probability of Misclassification*, là xác suất phân loại sai tổng cộng. Trong bài toán hai lớp, phân loại sai xảy ra trong hai trường hợp:

- Quan sát thực sự thuộc lớp C_1 nhưng bị phân loại vào lớp C_2 ;

- Quan sát thực sự thuộc lớp C_2 nhưng bị phân loại vào lớp C_1 .

Do đó:

$$TPM = P(\text{phân loại sai}).$$

Cụ thể:

$$TPM = P(\hat{C}_2|C_1)P(C_1) + P(\hat{C}_1|C_2)P(C_2).$$

Trong đó:

- $P(C_1)$ là xác suất tiên nghiệm của lớp C_1 ;
- $P(C_2)$ là xác suất tiên nghiệm của lớp C_2 ;
- $P(\hat{C}_2|C_1)$ là xác suất phân loại sai một quan sát thuộc lớp C_1 sang lớp C_2 ;
- $P(\hat{C}_1|C_2)$ là xác suất phân loại sai một quan sát thuộc lớp C_2 sang lớp C_1 .

Trong thực hành, nếu dùng mẫu kiểm định để ước lượng TPM, ta có:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n}.$$

Nghĩa là TPM được ước lượng bằng tỷ lệ số quan sát bị phân loại sai trên tổng số quan sát. Do đó, TPM càng nhỏ thì quy tắc phân loại càng tốt.

1.7.3 ECM – Expected Cost of Misclassification

ECM, viết đầy đủ là *Expected Cost of Misclassification*, là chi phí phân loại sai kỳ vọng. Trong trường hợp tổng quát, ECM có thể phụ thuộc vào từng loại chi phí phân loại sai. Tuy nhiên, trong phạm vi đề án này, ta chỉ xét hàm tổn thất 0 – 1, tức là mọi lỗi phân loại sai đều có chi phí bằng 1 và mọi trường hợp phân loại đúng đều có chi phí bằng 0.

Với hàm tổn thất 0 – 1, ta có:

$$c(1|1) = 0, \quad c(2|2) = 0,$$

và:

$$c(2|1) = 1, \quad c(1|2) = 1.$$

Khi đó, chi phí phân loại sai kỳ vọng được viết là:

$$ECM = c(2|1)P(\hat{C}_2|C_1)P(C_1) + c(1|2)P(\hat{C}_1|C_2)P(C_2).$$

Thay:

$$c(2|1) = 1, \quad c(1|2) = 1,$$

ta được:

$$ECM = P(\hat{C}_2|C_1)P(C_1) + P(\hat{C}_1|C_2)P(C_2).$$

Mà:

$$TPM = P(\hat{C}_2|C_1)P(C_1) + P(\hat{C}_1|C_2)P(C_2).$$

Do đó, trong trường hợp hàm tổn thất 0 – 1, ta có:

$$\boxed{ECM = TPM.}$$

Nếu ước lượng từ mẫu kiểm định, ta có:

$$\widehat{ECM} = \frac{n_{12}}{n} + \frac{n_{21}}{n}.$$

Suy ra:

$$\widehat{ECM} = \frac{n_{12} + n_{21}}{n}.$$

Mà:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n}.$$

Vì vậy:

$$\boxed{\widehat{ECM} = \widehat{TPM} = \frac{n_{12} + n_{21}}{n}.}$$

Điều này cho thấy, trong bối cảnh đồ án, việc tối thiểu hoá chi phí phân loại sai kỳ vọng tương đương với việc tối thiểu hoá xác suất phân loại sai tổng cộng.

1.7.4 Mối liên hệ giữa Accuracy, TPM và ECM

Từ ma trận nhầm lẫn, độ chính xác phân loại được xác định bởi:

$$\text{Accuracy} = \frac{n_{11} + n_{22}}{n}.$$

Trong khi đó, xác suất phân loại sai ước lượng là:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n}.$$

Vì:

$$n = n_{11} + n_{12} + n_{21} + n_{22},$$

nên:

$$\text{Accuracy} + \widehat{TPM} = 1.$$

Do đó:

$$\boxed{\text{Accuracy} = 1 - \widehat{TPM}.$$

Trong trường hợp hàm tổn thất 0 – 1:

$$\widehat{ECM} = \widehat{TPM}.$$

Suy ra:

$$\boxed{\text{Accuracy} = 1 - \widehat{ECM}.$$

Vì vậy, trong phạm vi đề án này, khi mọi lỗi phân loại sai đều có chi phí bằng 1, ta có thể đánh giá chất lượng của quy tắc phân loại thông qua các đại lượng:

$$\text{Accuracy}, \quad TPM, \quad ECM.$$

Trong đó, quy tắc phân loại càng tốt khi:

Accuracy càng lớn,

hoặc tương đương:

TPM càng nhỏ,

và:

ECM càng nhỏ.

Tóm lại, với hàm tổn thất $0 - 1$, ba đại lượng này có mối quan hệ trực tiếp:

$$\boxed{\text{Accuracy} = 1 - \widehat{TPM} = 1 - \widehat{ECM}.}$$

Chương 2

LDA cho bài toán phân loại hai lớp

2.1 Bài toán phân loại hai lớp

Bài toán phân loại hai lớp xét hai lớp C_1 và C_2 . Mỗi đối tượng cần phân loại được biểu diễn bởi vector đặc trưng:

$$X = x \in \mathbb{R}^d.$$

Trong chương này, ta sử dụng các kết quả đã chứng minh ở Chương 1 để xây dựng quy tắc phân loại Fisher và đánh giá độ chính xác phân loại trên dữ liệu mô phỏng.

2.1.1 Thiết lập bài toán và giả thiết mô hình xác suất

Giả sử hai lớp có phân phối chuẩn đa biến với cùng ma trận hiệp phương sai:

$$X|C_k \sim N_d(\mu_k, \Sigma), \quad k = 1, 2.$$

Trong đó μ_1, μ_2 là vector trung bình của hai lớp và Σ là ma trận hiệp phương sai chung. Trong phạm vi đề án, ta xét hàm tổn thất 0 – 1, tức là phân loại đúng có chi phí bằng 0 và phân loại sai có chi phí bằng 1.

Khi đó:

$$c(1|1) = c(2|2) = 0, \quad c(2|1) = c(1|2) = 1.$$

2.1.2 Quy tắc phân loại Bayes cho bài toán hai lớp

Với giả thiết hai lớp có cùng ma trận hiệp phương sai, quy tắc Bayes dẫn đến hàm phân biệt tuyến tính:

$$D(x) = (\mu_1 - \mu_2)^T \Sigma^{-1} \left(x - \frac{\mu_1 + \mu_2}{2} \right) + C.$$

Trong đó:

$$C = \ln \frac{P(C_1)}{P(C_2)}$$

trong trường hợp hàm tổn thất 0 – 1.

Nếu hai lớp có xác suất tiên nghiệm bằng nhau, tức là:

$$P(C_1) = P(C_2),$$

thì:

$$C = 0.$$

Khi đó, quy tắc phân loại trở thành:

$$D(x) > 0 \Rightarrow x \in C_1,$$

$$D(x) \leq 0 \Rightarrow x \in C_2.$$

2.1.3 Sự giao thoa và tương đương với tiếp cận của Fisher

Từ kết quả đã chứng minh ở Chương 1, hướng chiếu tối ưu của Fisher trong trường hợp hai lớp là:

$$\beta_{\text{opt}} = \Sigma_W^{-1}(\mu_1 - \mu_2).$$

Trong trường hợp giả thiết hai lớp có chung ma trận hiệp phương sai, Σ_W đóng vai trò tương ứng với Σ . Khi đó, ta có thể viết:

$$\beta_{\text{opt}} = \Sigma^{-1}(\mu_1 - \mu_2).$$

Do đó, hàm phân biệt Bayes có thể viết lại theo hướng Fisher:

$$D(x) = \beta_{\text{opt}}^T \left(x - \frac{\mu_1 + \mu_2}{2} \right) + C.$$

Nếu $P(C_1) = P(C_2)$ và dùng hàm tổn thất 0 – 1, ta có $C = 0$. Khi đó:

$$D(x) = \beta_{\text{opt}}^T \left(x - \frac{\mu_1 + \mu_2}{2} \right).$$

Đặt:

$$y = \beta_{\text{opt}}^T x,$$

và:

$$y_0 = \beta_{\text{opt}}^T \frac{\mu_1 + \mu_2}{2}.$$

Quy tắc phân loại trở thành:

$$y > y_0 \Rightarrow x \in C_1,$$

$$y \leq y_0 \Rightarrow x \in C_2.$$

Như vậy, trong trường hợp hai lớp chuẩn có cùng ma trận hiệp phương sai, quy tắc Bayes và quy tắc Fisher cho cùng một dạng hàm phân biệt tuyến tính.

2.1.4 Thủ tục Bayes Classifier trong thực nghiệm

Trong thực tế, các tham số tổng thể μ_1, μ_2, Σ thường chưa biết nên được thay bằng các ước lượng mẫu.

Gọi D_1, D_2 lần lượt là tập dữ liệu huấn luyện của hai lớp, với kích thước mẫu n_1, n_2 . Trung bình mẫu của từng lớp là:

$$m_k = \frac{1}{n_k} \sum_{x_i \in D_k} x_i, \quad k = 1, 2.$$

Ma trận hiệp phương sai mẫu gộp là:

$$S_p = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}.$$

Khi đó, hướng chiếu Fisher thực nghiệm được xác định bởi:

$$b_{\text{opt}} = S_p^{-1}(m_1 - m_2).$$

Hàm phân biệt thực nghiệm là:

$$\widehat{D}(x) = b_{\text{opt}}^T \left(x - \frac{m_1 + m_2}{2} \right) + \widehat{C}.$$

Trong trường hợp hai lớp cân bằng và dùng hàm tổn thất 0-1, ta có:

$$\widehat{C} = 0.$$

Do đó:

$$\widehat{D}(x) = b_{\text{opt}}^T \left(x - \frac{m_1 + m_2}{2} \right).$$

Quy tắc phân loại là:

$$\widehat{D}(x) > 0 \Rightarrow x \in C_1,$$

$$\widehat{D}(x) \leq 0 \Rightarrow x \in C_2.$$

2.1.5 Ví dụ minh họa: Bài toán phân loại hai chiều (Mô phỏng)

2.1.5.1 Hai lớp không thể tách biệt bởi biên tuyến tính

Xét bài toán phân loại hai chiều ($d = 2$). Dữ liệu được sinh ngẫu nhiên từ hai phân phối chuẩn hai chiều có cùng ma trận hiệp phương sai.

Thiết lập mô phỏng:

$$n_1 = n_2 = 500.$$

$$\mu_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \mu_2 = \begin{pmatrix} 4 \\ 4 \end{pmatrix}.$$

$$\Sigma = \begin{pmatrix} 2 & -1,5 \\ -1,5 & 2 \end{pmatrix}.$$

Do $n_1 = n_2$, ta có:

$$\widehat{P}(C_1) = \widehat{P}(C_2) = 0,5.$$

Vì vậy, trong trường hợp hàm tổn thất $0 - 1$, hằng số ngưỡng xấp xỉ bằng 0.


Từ dữ liệu mô phỏng, ta tính m_1, m_2 và S_p , sau đó xác định:

$$b_{\text{opt}} = S_p^{-1}(m_1 - m_2).$$

Đường phân loại LDA được xác định bởi:

$$b_{\text{opt}}^T \left(x - \frac{m_1 + m_2}{2} \right) = 0.$$

Từ Hình 2.1, hai lớp dữ liệu có dạng ellipse nghiêng do phần tử ngoài đường chéo của ma trận hiệp phương sai âm:




Hình 2.1: Phân bố mẫu của hai lớp chuẩn hai chiều và đường phân loại LDA.

$$\sigma_{12} = -1,5 < 0.$$

Điều này thể hiện mối tương quan âm giữa hai biến đặc trưng. Đường LDA chia không gian thành hai miền quyết định tương ứng với hai lớp C_1 và C_2 .

Để đánh giá kết quả phân loại, ta sử dụng ma trận nhập nhằng.



Hình 2.2: Ma trận nhập nhằng dùng để đánh giá kết quả phân loại của mô hình LDA.

Từ ma trận nhập nhằng hiển thị trên Hình 2.2, ta xác định được số lượng các mẫu phân loại đúng và phân loại sai tương ứng của hai lớp. Cụ thể, số mẫu thuộc lớp C_1 phân loại đúng là $n_{11} = 429$, số mẫu phân loại sai sang lớp C_2 là $n_{12} = 71$. Đối với lớp C_2 , số mẫu phân loại đúng là $n_{22} = 414$ và số mẫu phân loại sai sang lớp C_1 là $n_{21} = 86$.

Tỷ lệ lỗi thực nghiệm (Tỷ lệ phân loại sai - $\widehat{TPM}$) được tính toán cụ thể như sau:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n} = \frac{71 + 86}{1000} = \frac{157}{1000} = 0,157 \quad (15,7\%).$$

Do đồ án sử dụng hàm tổn thất 0 – 1, tổn thất trung bình thực nghiệm bằng chính tỷ lệ lỗi:

$$\widehat{ECM} = \widehat{TPM} = 0,157.$$

Độ chính xác phân loại (Accuracy) toàn cục của mô hình LDA đạt:

$$\text{Accuracy} = 1 - \widehat{TPM} = 1 - 0,157 = 0,843 \quad (84,3\%).$$

Trong phần trước, ta đã xét trường hợp hai lớp chuẩn hai chiều có vùng giao nhau

nhất định. Để thấy rõ hơn hạn chế của bộ phân loại tuyến tính khi dữ liệu có mức độ chồng lấn cao, ta tiếp tục xét một mô phỏng khác, trong đó hai lớp có tâm rất gần nhau và cùng ma trận hiệp phương sai.

Thiết lập mô phỏng được cho bởi:

$$n_1 = n_2 = 500.$$

Hai vector trung bình được chọn là:

$$\mu_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \mu_2 = \begin{pmatrix} 3,2 \\ 2,5 \end{pmatrix}.$$

Hai lớp được giả sử có cùng ma trận hiệp phương sai:

$$\Sigma_1 = \Sigma_2 = \Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Khác với trường hợp trước, phần tử ngoài đường chéo của ma trận hiệp phương sai là:

$$\sigma_{12} = 1 > 0.$$

Do đó, hai biến đặc trưng có mối tương quan dương. Về mặt hình học, các đám mây điểm và các ellipse mật độ có xu hướng nghiêng theo hướng đi lên từ trái sang phải.

Do hai lớp có cùng số lượng quan sát, xác suất tiên nghiệm được ước lượng bởi:

$$\hat{P}(C_1) = \hat{P}(C_2) = 0,5.$$


Vì vậy, trong trường hợp hàm tổn thất 0 – 1, quy tắc phân loại Bayes dựa trên LDA chủ yếu phụ thuộc vào khoảng cách Mahalanobis giữa điểm quan sát và hai lớp.

Từ dữ liệu mô phỏng, ta tính trung bình mẫu m_1, m_2 và ma trận hiệp phương sai gộp S_p . Khi đó, vector pháp tuyến của biên quyết định LDA được xác định bởi:

$$b_{\text{opt}} = S_p^{-1}(m_1 - m_2).$$

Đường phân loại tuyến tính của LDA có dạng:

$$b_{\text{opt}}^T \left(x - \frac{m_1 + m_2}{2} \right) = 0.$$



Hình 2.3: Phân bố mẫu của hai lớp chuẩn hai chiều có tương quan dương và mức độ chồng lấn lớn.

Từ Hình 2.3, có thể thấy hai lớp dữ liệu chồng lấn mạnh trong không gian hai chiều. Nguyên nhân chính là do khoảng cách giữa hai vector trung bình:

$$\mu_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \mu_2 = \begin{pmatrix} 3,2 \\ 2,5 \end{pmatrix}$$

khá nhỏ so với độ phân tán của dữ liệu được xác định bởi ma trận hiệp phương sai:

$$\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$


Khoảng cách Euclid giữa hai tâm chỉ là:

$$\|\mu_1 - \mu_2\| = \sqrt{(3 - 3,2)^2 + (3 - 2,5)^2} = \sqrt{0,04 + 0,25} = \sqrt{0,29} \approx 0,539.$$

Trong khi đó, phương sai theo từng trục đều bằng 2, cho thấy độ phân tán của mỗi lớp tương đối lớn. Vì vậy, mặc dù hai lớp có hai tâm khác nhau, phần lớn các điểm dữ liệu vẫn nằm xen kẽ trong cùng một vùng không gian.

Đường LDA vẫn chia không gian thành hai miền quyết định tuyến tính. Tuy nhiên, do vùng giao nhau giữa hai phân phối quá lớn, nhiều điểm của lớp C_1 nằm về phía miền quyết định của lớp C_2 và ngược lại. Đây là nguyên nhân làm tăng tỷ lệ phân loại sai.

Để đánh giá kết quả phân loại, ta tiếp tục sử dụng ma trận nhập nhằng.



Hình 2.4: Ma trận nhập nhằng của mô hình LDA trong trường hợp hai lớp chồng lấn nhiều.

Từ ma trận nhập nhằng hiển thị trên Hình 2.4, ta xác định được số lượng các mẫu phân loại đúng và phân loại sai tương ứng của hai lớp. Cụ thể, số mẫu thuộc lớp C_1 phân loại đúng là $n_{11} = 289$, số mẫu phân loại sai sang lớp C_2 là $n_{12} = 211$. Đối với lớp C_2 , số mẫu phân loại đúng là $n_{22} = 306$ và số mẫu phân loại sai sang lớp C_1 là $n_{21} = 194$.

Tỷ lệ lỗi thực nghiệm được tính bởi:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n} = \frac{211 + 194}{1000} = \frac{405}{1000} = 0,405.$$

Hay tương đương,

$$\widehat{TPM} = 40,5\%.$$

Do đồ án sử dụng hàm tổn thất 0 – 1, tổn thất trung bình thực nghiệm bằng chính tỷ lệ lỗi:

$$\widehat{ECM} = \widehat{TPM} = 0,405.$$

Độ chính xác phân loại toàn cục của mô hình LDA là:

$$\text{Accuracy} = 1 - \widehat{TPM} = 1 - 0,405 = 0,595.$$

Hay,

$$\text{Accuracy} = 59,5\%.$$

Kết quả này cho thấy khi hai lớp có mức độ chồng lấn lớn, hiệu quả phân loại của LDA giảm đáng kể. Mặc dù LDA vẫn xác định được một đường phân loại tuyến tính, đường này không thể tách hoàn toàn hai lớp do phần lớn các quan sát của hai lớp nằm xen kẽ trong cùng một vùng không gian. Sai số phân loại 40,5% phản ánh mức độ khó của bài toán, xuất phát từ việc hai phân phối có tâm rất gần nhau so với độ phân tán của dữ liệu.

Trong trường hợp này, sai số không chủ yếu đến từ việc lựa chọn sai dạng mô hình, vì hai lớp vẫn được sinh từ các phân phối chuẩn có cùng ma trận hiệp phương sai. Nguyên nhân chính là vùng chồng lấn giữa hai phân phối quá lớn, làm cho nhiều điểm thuộc lớp C_1 có đặc trưng gần giống với lớp C_2 và ngược lại. Do đó, ngay cả biên quyết định tuyến tính tối ưu theo LDA cũng không thể đạt độ chính xác cao.

Trường hợp mô phỏng này cho thấy khi hai phân phối chuẩn có tâm quá gần nhau so với độ phân tán nội tại, vùng chồng lấn giữa hai lớp trở nên rất lớn. Khi đó, ngay cả khi giả thiết của LDA được thỏa mãn, tức là hai lớp có cùng ma trận hiệp phương sai và biên Bayes là tuyến tính, mô hình vẫn không thể phân loại chính xác tuyệt đối. Sai số phân loại không xuất phát từ việc chọn sai dạng biên quyết định, mà xuất phát từ bản chất xác suất của dữ liệu: cùng một vùng không gian có thể đồng thời chứa các quan sát thuộc cả hai lớp.

Qua các mô phỏng trên, có thể thấy hiệu quả của phương pháp Fisher LDA phụ thuộc mạnh vào cấu trúc phân bố của dữ liệu. Khi hai lớp có tâm cách xa nhau và mức độ chồng lấn nhỏ, LDA xác định được một biên phân loại tuyến tính tương đối

tốt, cho tỷ lệ phân loại sai thấp. Ngược lại, khi hai lớp có tâm gần nhau, phương sai lớn hoặc vùng chồng lấn giữa hai phân phối trở nên đáng kể, tỷ lệ lỗi phân loại tăng lên rõ rệt.

Trong cả hai trường hợp mô phỏng, dữ liệu đều được sinh từ các phân phối chuẩn hai chiều có cùng ma trận hiệp phương sai, nên giả thiết cơ bản của LDA được thỏa mãn. Vì vậy, đường phân loại thu được chính là biên tuyến tính tối ưu theo tiêu chuẩn Bayes trong mô hình đang xét. Tuy nhiên, tối ưu theo nghĩa Bayes không có nghĩa là phân loại chính xác tuyệt đối. Khi hai phân phối có vùng giao nhau, luôn tồn tại những quan sát mang đặc trưng gần giống nhau mặc dù thuộc hai lớp khác nhau. Đây là nguyên nhân bản chất dẫn đến sai số phân loại.

Trường hợp hai lớp chồng lấn ít cho thấy LDA có thể đạt độ chính xác khá cao, chẳng hạn tỷ lệ lỗi thực nghiệm khoảng 15,7%. Trong khi đó, ở trường hợp hai lớp chồng lấn mạnh, tỷ lệ lỗi tăng lên đến 40,5%, tương ứng độ chính xác chỉ còn 59,5%. Sự khác biệt này minh họa rõ rằng khả năng phân tách của LDA không chỉ phụ thuộc vào việc có tồn tại biên tuyến tính hay không, mà còn phụ thuộc vào mức độ tách biệt thực sự giữa các phân phối lớp.

Như vậy, Fisher LDA là một phương pháp hiệu quả khi dữ liệu có cấu trúc lớp tương đối rõ ràng và giả thiết đồng hiệp phương sai phù hợp. Tuy nhiên, trong các bài toán mà các lớp chồng lấn mạnh, ngay cả biên tuyến tính tối ưu cũng khó đạt hiệu quả phân loại cao. Điều này cho thấy khi áp dụng LDA trong thực hành, cần xem xét đồng thời các yếu tố như khoảng cách giữa các tâm lớp, độ phân tán trong lớp và mức độ giao nhau giữa các phân phối.

2.1.5.2 Hai lớp là tách biệt hoàn toàn bởi một biên tuyến tính

Xét bài toán phân loại hai chiều ($d = 2$) tương tự nhưng trong điều kiện hai phân phối có khoảng cách tâm (trung bình) đủ lớn, khiến vùng chồng lấn mật độ giữa hai lớp tiến về 0.

Thiết lập mô phỏng:

$$n_1 = n_2 = 500.$$

$$\mu_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mu_2 = \begin{pmatrix} 7 \\ 7 \end{pmatrix}.$$

$$\Sigma = \begin{pmatrix} 1,5 & -0,8 \\ -0,8 & 1,5 \end{pmatrix}.$$

Do quy mô mẫu ở hai lớp bằng nhau ($n_1 = n_2$), ta tiếp tục có tỷ lệ mẫu tiên nghiệm

cân bằng:


$$\hat{P}(C_1) = \hat{P}(C_2) = 0,5.$$

Vì vậy, cấu trúc hằng số ngưỡng đối với hàm tổn thất 0 – 1 vẫn xấp xỉ bằng 0. Từ dữ liệu mô phỏng mới, sau khi tính toán các vector trung bình mẫu m_1, m_2 và ma trận hiệp phương sai gộp S_p , vector hệ số tối ưu được xác định bởi:

$$b_{\text{opt}} = S_p^{-1}(m_1 - m_2).$$

Đường phân loại tuyến tính LDA được xác định qua phương trình biên quyết định quen thuộc:


$$b_{\text{opt}}^T \left(x - \frac{m_1 + m_2}{2} \right) = 0.$$



Hình 2.5: Phân bố mẫu của hai lớp tách biệt tuyến tính hoàn toàn và đường phân loại LDA.

Từ Hình 2.5, do khoảng cách giữa hai vector trung bình thực tế μ_1 và μ_2 lớn hơn rất nhiều so với độ phân tán cục bộ được quy định bởi ma trận hiệp phương sai Σ , hai tập hợp dữ liệu tạo thành hai cụm ellipse nghiêng biệt lập rõ rệt mà không hề có vùng giao thoa. Đường biên quyết định của phương pháp LDA đi qua trung điểm của đoạn nối hai tâm mẫu và phân tách hoàn hảo hai vùng không gian.

Để đánh giá hiệu năng của mô hình trong kịch bản lý tưởng này, ta quan sát ma trận nhập nhằng thực nghiệm thu được từ quá trình phân loại.



Hình 2.6: Ma trận nhập nhằng trong trường hợp hai lớp tách biệt hoàn toàn.

Đánh giá tỷ lệ lỗi và độ chính xác phân loại: Dựa trên kết quả từ ma trận nhập nhằng trên Hình 2.6, các phần tử nằm ngoài đường chéo chính đại diện cho số lượng mẫu bị phân loại sai đều bằng 0 (tức là $n_{12} = n_{21} = 0$).

Tỷ lệ lỗi thực nghiệm (Tỷ lệ phân loại sai - Misclassification Rate hay $\widehat{TPM}$) được tính toán như sau:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n} = \frac{0 + 0}{1000} = 0.$$

Do đồ án áp dụng hàm tổn thất 0 – 1, ta suy ra tổn thất trung bình thực nghiệm ($\widehat{ECM}$) cũng triệt tiêu và bằng chính tỷ lệ lỗi:

$$\widehat{ECM} = \widehat{TPM} = 0.$$

Từ đó, độ chính xác phân loại (Accuracy) của mô hình LDA đạt giá trị tối đa:

$$\text{Accuracy} = 1 - \widehat{TPM} = 1 - 0 = 1 \quad (100\%).$$

Kết quả mô phỏng trong trường hợp này khẳng định rằng khi dữ liệu thỏa mãn điều kiện tách biệt tuyến tính hoàn hảo (linearly separable), phương pháp Fisher LDA cho

phép tìm ra một siêu phẳng phân chia lý tưởng. Mô hình đạt độ chính xác tuyệt đối 100% và tỷ lệ lỗi thực nghiệm hoàn toàn triệt tiêu do không tồn tại bất kỳ điểm dữ liệu nào nằm trong vùng chồng lấn mật độ.

Trường hợp hai đám mây không tương quan và được tách bởi đường trung trực của hai tâm: Để làm rõ thêm ý nghĩa hình học của biên phân loại LDA, ta xét một trường hợp đặc biệt hơn, trong đó hai lớp có ma trận hiệp phương sai dạng bội của ma trận đơn vị. Khi đó, hai biến đặc trưng không tương quan và có cùng phương sai theo mọi hướng. Do đó, các đường đồng mức mật độ của hai phân phối chuẩn có dạng đường tròn.

Thiết lập mô phỏng được cho bởi:

$$n_1 = n_2 = 500.$$

Hai vector trung bình được chọn là:

$$\mu_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \mu_2 = \begin{pmatrix} 12,5 \\ 3 \end{pmatrix}.$$

Hai lớp có cùng ma trận hiệp phương sai:

$$\Sigma_1 = \Sigma_2 = \Sigma = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}.$$

Do các phần tử ngoài đường chéo của ma trận hiệp phương sai bằng 0, ta có:

$$\sigma_{12} = 0.$$

Điều này cho thấy hai biến đặc trưng x_1 và x_2 không có tương quan tuyến tính. Đồng thời, do hai phần tử trên đường chéo chính bằng nhau, tức là:

$$\sigma_1^2 = \sigma_2^2 = 2,$$

nên mức độ phân tán theo hai hướng x_1 và x_2 là như nhau. Vì vậy, các đám mây điểm của hai lớp có dạng gần tròn.

Do hai lớp có cùng số lượng quan sát nên xác suất tiên nghiệm được ước lượng bởi:

$$\hat{P}(C_1) = \hat{P}(C_2) = 0,5.$$

Trong trường hợp này, do hai lớp có cùng ma trận hiệp phương sai và cùng xác suất

tiên nghiệm, biên quyết định LDA tương ứng với tập hợp các điểm có khoảng cách Mahalanobis đến hai tâm bằng nhau. Tuy nhiên, vì

$$\Sigma = 2I,$$

khoảng cách Mahalanobis chỉ khác khoảng cách Euclid một hệ số tỷ lệ. Do đó, biên quyết định LDA chính là đường trung trực của đoạn nối hai tâm μ_1 và μ_2 .

Trung điểm của hai vector trung bình là:

$$M = \frac{\mu_1 + \mu_2}{2} = \begin{pmatrix} \frac{3+12,5}{2} \\ \frac{3+3}{2} \end{pmatrix} = \begin{pmatrix} 7,75 \\ 3 \end{pmatrix}.$$

Vì hai tâm có cùng tung độ và chỉ khác nhau theo phương x_1 , đoạn nối hai tâm là một đoạn thẳng nằm ngang. Do đó, đường trung trực của đoạn nối hai tâm là đường thẳng đứng đi qua hoành độ của trung điểm:

$$x_1 = 7,75.$$


Mặt khác, nếu xét theo công thức LDA, vector pháp tuyến của biên phân loại được xác định bởi:

$$b_{\text{opt}} = S_p^{-1}(m_1 - m_2).$$

Với S_p xấp xỉ ma trận $2I$, ta có:

$$b_{\text{opt}} \approx \frac{1}{2}(m_1 - m_2).$$

Do đó, hướng pháp tuyến của biên phân loại cùng phương với đoạn nối hai tâm. Vì đoạn nối hai tâm song song với trục x_1 , nên biên phân loại vuông góc với trục này và có dạng một đường thẳng đứng.



Hình 2.7: Hai đám mây chuẩn hai chiều không tương quan, có dạng tròn và được phân tách bởi đường trung trực của hai tâm.

Từ Hình 2.7, có thể thấy hai lớp tạo thành hai cụm dữ liệu gần tròn, tách biệt rõ ràng trong không gian hai chiều. Đường phân loại LDA là đường thẳng đứng nằm giữa hai cụm dữ liệu, đi qua trung điểm của đoạn nối hai tâm. Trong trường hợp này, biên phân loại không chỉ là một đường thẳng tối ưu theo LDA mà còn có ý nghĩa hình học rất trực quan: mỗi điểm dữ liệu được gán vào lớp có tâm gần nó hơn.

Kết quả phân loại cho thấy không có điểm dữ liệu nào bị phân loại sai. Ma trận nhập nhằng thực nghiệm có dạng:

	Dự đoán C_1	Dự đoán C_2
Thực tế C_1	500	0
Thực tế C_2	0	500

Từ ma trận trên, các phần tử ngoài đường chéo chính đều bằng 0, tức là:

$$n_{12} = 0, \quad n_{21} = 0.$$

Do đó, tỷ lệ lỗi thực nghiệm là:

$$\widehat{TPM} = \frac{n_{12} + n_{21}}{n} = \frac{0 + 0}{1000} = 0.$$

Với hàm tổn thất 0 – 1, tổn thất trung bình thực nghiệm cũng bằng:

$$\widehat{ECM} = \widehat{TPM} = 0.$$

Độ chính xác phân loại đạt:

$$\text{Accuracy} = 1 - \widehat{TPM} = 1 - 0 = 1.$$

Hay tương đương:

$$\text{Accuracy} = 100\%.$$

Trường hợp này cho thấy khi hai lớp có cùng ma trận hiệp phương sai dạng $\sigma^2 I$, không có tương quan giữa các biến đặc trưng và hai tâm cách xa nhau, LDA đưa ra một biên phân loại rất trực quan: đường trung trực của đoạn nối hai tâm. Đây là một trường hợp đặc biệt trong đó quy tắc phân loại LDA tương đương với quy tắc gán điểm vào lớp có tâm gần nhất theo khoảng cách Euclid. Khi khoảng cách giữa hai tâm đủ lớn so với độ phân tán trong từng lớp, hai đám mây dữ liệu được phân tách hoàn toàn và tỷ lệ lỗi thực nghiệm bằng 0.

Tài liệu tham khảo

- [1] Đặng Phước Huy, *Thống kê toán học*, Đại học Đà lạt, 2010.
- [2] R. A. Fisher, *The Use of Multiple Measurements in Taxonomic Problems*, Annals of Eugenics, 7(2), 179–188, 1936.
- [3] Christopher M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [4] Trevor Hastie, Robert Tibshirani, Jerome Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, 2009.
- [5] Johnson R. A., Wichern D. W., *Applied Multivariate Statistical Analysis*, Pearson Prentice Hall, Pearson Education, Inc, 2007.