

Tiếp cận phương pháp LDA của R.A. Fisher trong phân loại mẫu thống kê

Phùng Ngọc Bảo – 2212318



Khoa Toán – Tin học, Trường Đại học Đà Lạt

Giảng viên hướng dẫn: Đặng Phước Huy, Huỳnh Bảo Tuyên

Ngày 2 tháng 6 năm 2026

- Trình bày cơ sở lý thuyết của phương pháp LDA.
- Làm rõ ý tưởng hình học trong tiếp cận của Fisher.
- Xây dựng hàm phân biệt LDA theo lý thuyết Bayes.
- Chỉ ra sự tương đồng giữa hai cách tiếp cận.
- Minh họa phương pháp LDA của Fisher trên dữ liệu Iris và dữ liệu mô phỏng.

Nội dung trình bày

- ➊ Giới thiệu bài toán phân loại mẫu thống kê.
- ➋ Tiếp cận LDA của Fisher.
- ➌ Tiếp cận LDA theo lý thuyết Bayes.
- ➍ Sự tương đương giữa Fisher và Bayes.
- ➎ Minh họa một chiều trên bộ dữ liệu Iris.
- ➏ Minh họa hai chiều trên dữ liệu mô phỏng.
- ➐ Kết luận và hướng phát triển.

Bài toán phân loại mẫu thống kê

Cho tập dữ liệu huấn luyện gồm n quan sát

$$\mathcal{D} = \{(\mathbf{x}_i, y_i) : i = 1, 2, \dots, n\},$$

trong đó $\mathbf{x}_i \in \mathbb{R}^d$ là vectơ đặc trưng của quan sát thứ i , còn y_i là nhãn lớp tương ứng. Giả sử bài toán có K lớp

$$C_1, C_2, \dots, C_K,$$

khi đó nhãn lớp thỏa mãn

$$y_i \in \{1, 2, \dots, K\}.$$

Nếu $y_i = k$, ta nói quan sát $\mathbf{x}_i$ thuộc lớp C_k . Với một quan sát mới $\mathbf{x}$, mục tiêu là xây dựng quy tắc phân loại

$$\hat{G}(\mathbf{x}) \in \{C_1, C_2, \dots, C_K\},$$

sao cho quan sát mới được gán vào lớp phù hợp nhất.

Mục tiêu

Tìm một biên quyết định giúp phân tách các lớp trong không gian đặc trưng.


Tiếp cận Fisher: Ý tưởng hình học

Câu hỏi của Fisher

Có thể tìm một hướng chiếu tuyến tính sao cho sau khi chiếu, hai lớp được tách biệt tốt nhất hay không?

Một hướng chiếu tốt cần thỏa:

- Trung bình hai lớp sau chiếu cách xa nhau.
- Dữ liệu trong từng lớp sau chiếu có độ phân tán thấp.



Hình minh họa ý tưởng hình học của Fisher LDA, xem tài liệu [7].

Ma trận tán xạ giữa lớp và trong lớp

Xét bài toán phân loại hai lớp C_1 và C_2 . Gọi $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2$ lần lượt là vectơ trung bình của hai lớp, còn $\boldsymbol{\mu}$ là vectơ trung bình của toàn bộ dữ liệu. Ma trận tán xạ giữa hai lớp

$$\Sigma_B = n_1(\boldsymbol{\mu}_1 - \boldsymbol{\mu})(\boldsymbol{\mu}_1 - \boldsymbol{\mu})^T + n_2(\boldsymbol{\mu}_2 - \boldsymbol{\mu})(\boldsymbol{\mu}_2 - \boldsymbol{\mu})^T.$$

Ma trận tán xạ trong lớp

$$\Sigma_W = \sum_{\mathbf{x}_i \in C_1} (\mathbf{x}_i - \boldsymbol{\mu}_1)(\mathbf{x}_i - \boldsymbol{\mu}_1)^T + \sum_{\mathbf{x}_i \in C_2} (\mathbf{x}_i - \boldsymbol{\mu}_2)(\mathbf{x}_i - \boldsymbol{\mu}_2)^T.$$

Tiêu chuẩn Fisher

Trong trường hợp hai lớp, Fisher chiếu mỗi quan sát $\mathbf{x} \in \mathbb{R}^d$ lên một trục có phương $\boldsymbol{\beta}$

$$z = \boldsymbol{\beta}^T \mathbf{x}.$$

Sau phép chiếu, mong muốn:

- Hai trung bình lớp cách xa nhau.
- Các điểm trong cùng một lớp ít phân tán.

Do đó, tiêu chuẩn Fisher được xác định bởi

$$J(\boldsymbol{\beta}) = \frac{\boldsymbol{\beta}^T \Sigma_B \boldsymbol{\beta}}{\boldsymbol{\beta}^T \Sigma_W \boldsymbol{\beta}}.$$

Bài toán tối ưu

Tìm hướng chiếu $\boldsymbol{\beta} \neq \mathbf{0}$ sao cho

$$\boldsymbol{\beta}_{\text{opt}} = \arg \max_{\boldsymbol{\beta} \neq \mathbf{0}} J(\boldsymbol{\beta}).$$

Liên hệ với thương Rayleigh

Từ tiêu chuẩn Fisher, ta cần giải bài toán tối ưu

$$\max_{\beta \neq 0} J(\beta) = \max_{\beta \neq 0} \frac{\beta^T \Sigma_B \beta}{\beta^T \Sigma_W \beta}. \quad (1)$$

Σ_W là ma trận xác định dương. Đặt

$$\mathbf{y} = \Sigma_W^{1/2} \beta, \quad \beta = \Sigma_W^{-1/2} \mathbf{y}. \quad (2)$$

Khi đó, tiêu chuẩn Fisher được đưa về dạng thương Rayleigh

$$J(\beta) = \frac{\mathbf{y}^T S \mathbf{y}}{\mathbf{y}^T \mathbf{y}}, \quad S = \Sigma_W^{-1/2} \Sigma_B \Sigma_W^{-1/2}. \quad (3)$$

Nhận xét

Cực đại của thương Rayleigh đạt tại vectơ riêng ứng với giá trị riêng lớn nhất của S .

Nghiệm tối ưu Fisher

Từ bài toán tối ưu theo tiêu chuẩn Fisher và dạng thương Rayleigh, ta thu được phương chiều tối ưu của Fisher

$$\beta_{\text{opt}} \propto \Sigma_W^{-1}(\mu_1 - \mu_2). \quad (4)$$

Do phương chiều không thay đổi khi nhân β với một hằng số khác 0, ta thường chọn

$$\beta_{\text{opt}} = \Sigma_W^{-1}(\mu_1 - \mu_2). \quad (5)$$

Ý nghĩa

β_{opt} là hướng chiều làm tăng khoảng cách giữa hai lớp sau chiếu, đồng thời giảm độ phân tán trong từng lớp.

Biên phân loại theo Fisher

Sau khi xác định hướng chiếu tối ưu β_{opt} , mỗi quan sát $\mathbf{x}$ được chiếu lên trục một chiều:

$$y = \beta_{\text{opt}}^T \mathbf{x}. \quad (6)$$

Trung bình của hai lớp sau chiếu là

$$\bar{y}_k = \beta_{\text{opt}}^T \boldsymbol{\mu}_k, \quad k = 1, 2.$$

Luật phân lớp theo Fisher được xác định bởi

$$\hat{G}(\mathbf{x}) = \arg \min_{k=1,2} |y - \bar{y}_k|. \quad (7)$$

Biên tách biệt là điểm có khoảng cách đến hai trung bình sau chiếu bằng nhau

$$|y_{\text{bnd}} - \bar{y}_1| = |y_{\text{bnd}} - \bar{y}_2|. \quad (8)$$

Phương trình biên

$$[\Sigma_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)]^T \mathbf{x}_{\text{bnd}} - \frac{1}{2} (\boldsymbol{\mu}_1^T \Sigma_W^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \Sigma_W^{-1} \boldsymbol{\mu}_2) = 0. \quad (9)$$

Tiếp cận Bayes trong phân loại

Giả sử với mỗi lớp C_k , ta có

$$(\mathbf{X} \mid G = k) \sim f_k(\mathbf{x}), \quad P(G = k) = \pi_k, \quad k = 1, 2, \dots, K. \quad (10)$$

Theo quy tắc Bayes, với quan sát $\mathbf{x}$, ta gán $\mathbf{x}$ vào lớp có xác suất hậu nghiệm lớn nhất

$$G_B(\mathbf{x}) = \arg \max_k P(G = k \mid \mathbf{X} = \mathbf{x}). \quad (11)$$

Theo công thức Bayes,

$$P(G = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{\ell=1}^K \pi_\ell f_\ell(\mathbf{x})} \propto \pi_k f_k(\mathbf{x}). \quad (12)$$

Quy tắc phân loại Bayes được viết gọn thành

$$G_B(\mathbf{x}) = \arg \max_k \{ \pi_k f_k(\mathbf{x}) \}. \quad (13)$$

Mô hình Gauss và hàm tách biệt

Giả sử hai lớp có phân phối chuẩn nhiều chiều với cùng ma trận hiệp phương sai

$$(\mathbf{X} \mid G = k) \sim N_d(\boldsymbol{\mu}_k, \Sigma), \quad P(G = k) = \pi_k, \quad k = 1, 2. \quad (14)$$

Khi đó, mật độ điều kiện trên từng lớp là

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\}. \quad (15)$$

Từ quy tắc Bayes, hàm tách biệt Bayes

$$\delta_k(\mathbf{x}) = -\frac{1}{2} \ln |\Sigma| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \ln \pi_k. \quad (16)$$

Hàm tách biệt rút gọn thành

$$\delta_k(\mathbf{x}) = \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \ln \pi_k. \quad (17)$$

Biên quyết định Bayes hai lớp

Trong bài toán hai lớp, biên quyết định Bayes được xác định bởi

$$\delta_1(\mathbf{x}) = \delta_2(\mathbf{x}). \quad (18)$$

Từ hàm phân biệt rút gọn, ta thu được

$$\mathbf{x}^T \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) - \frac{1}{2} (\boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2) + \ln \frac{\pi_1}{\pi_2} = 0. \quad (19)$$

Nếu $\pi_1 = \pi_2$, thì $\ln \frac{\pi_1}{\pi_2} = 0$.

Trong thực nghiệm

$$\pi_k \approx \hat{\pi}_k, \quad \boldsymbol{\mu}_k \approx \hat{\boldsymbol{\mu}}_k, \quad \Sigma \approx \hat{\Sigma}.$$

Biên quyết định thực nghiệm khi $\hat{\pi}_1 = \hat{\pi}_2$

$$\mathbf{x}^T \hat{\Sigma}^{-1}(\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2) - \frac{1}{2} (\hat{\boldsymbol{\mu}}_1^T \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2^T \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_2) = 0. \quad (20)$$

Phương trình biên quyết định

Từ phương trình (20), xét các điểm $\mathbf{x}_{\text{bnd}}$ nằm trên đường biên

$$\mathbf{x}_{\text{bnd}}^T \hat{\Sigma}^{-1} (\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2) - \frac{1}{2} \left(\hat{\boldsymbol{\mu}}_1^T \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2^T \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_2 \right) = 0.$$

Do $\hat{\Sigma}^{-1}$ là ma trận đối xứng, ta có

$$\hat{\boldsymbol{\mu}}_1^T \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2^T \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_2 = (\hat{\boldsymbol{\mu}}_1 + \hat{\boldsymbol{\mu}}_2)^T \hat{\Sigma}^{-1} (\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2).$$

Thay vào phương trình trên và nhóm nhân tử chung, ta được

$$\left(\mathbf{x}_{\text{bnd}} - \frac{\hat{\boldsymbol{\mu}}_1 + \hat{\boldsymbol{\mu}}_2}{2} \right)^T \hat{\Sigma}^{-1} (\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2) = 0.$$

Biên phân loại theo $\mathbf{b}_{\text{opt}}$

$$\mathbf{b}_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\hat{\boldsymbol{\mu}}_1 + \hat{\boldsymbol{\mu}}_2}{2} \right) = 0.$$

Đánh giá kết quả phân loại

Với hàm tổn thất 0 – 1, phân loại đúng có chi phí 0, phân loại sai có chi phí 1. Kết quả phân loại được tổng hợp bằng ma trận lỗi:

Các lớp dự báo	Các lớp đúng		Tổng cộng
	C_1	C_2	
$\hat{C}_1$	n_{11}	n_{12}	$n_{1\bullet}$
$\hat{C}_2$	n_{21}	n_{22}	$n_{2\bullet}$
Tổng cộng	$n_{\bullet 1}$	$n_{\bullet 2}$	n

Trong đó, n_{ij} là số quan sát được dự báo vào lớp $\hat{C}_i$ và thực tế thuộc lớp C_j .

$$\text{Overall Accuracy} = \frac{n_{11} + n_{22}}{n}, \quad \text{TPM} = \frac{n_{12} + n_{21}}{n}.$$

$$\underbrace{P(\hat{C}_j | C_j) = \frac{n_{jj}}{n_{\bullet j}}}_{\text{Recall của lớp } C_j}, \quad \underbrace{P(C_j | \hat{C}_j) = \frac{n_{jj}}{n_{j\bullet}}}_{\text{Precision của lớp } C_j}, \quad j = 1, 2.$$

Giới thiệu bộ dữ liệu Iris

Bộ dữ liệu Iris gồm 150 quan sát, chia đều cho 3 lớp hoa:

$$C_1 = \textit{setosa}, \quad C_2 = \textit{versicolor}, \quad C_3 = \textit{virginica}.$$

Mỗi quan sát có 4 thuộc tính:

Sepal.Length, Sepal.Width, Petal.Length, Petal.Width.

STT	Sepal.L	Sepal.W	Petal.L	Petal.W	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa

Trong đồ án, bộ dữ liệu này được dùng để minh họa quy tắc phân loại một chiều bằng LDA.

Minh họa phân loại 1 chiều: Versicolor và Virginica

Xét thuộc tính *Petal.Length* với hai lớp

$$C_1 = \text{versicolor}, \quad C_2 = \text{virginica}.$$

Từ dữ liệu Iris, ta có

$$n_1 = n_2 = 50, \quad \hat{\pi}_1 = \hat{\pi}_2 = \frac{1}{2}.$$

Trung bình mẫu và phương sai mẫu của hai lớp là


$$\hat{\mu}_1 = 4,260 \text{ cm}, \quad s_1^2 = 0,2208 \text{ cm}^2, \quad \hat{\mu}_2 = 5,552 \text{ cm}, \quad s_2^2 = 0,3046 \text{ cm}^2.$$

Vì $\hat{\pi}_1 = \hat{\pi}_2$, ngưỡng LDA là trung điểm hai trung bình:

$$x_{\text{bnd}} = \frac{\hat{\mu}_1 + \hat{\mu}_2}{2} = \frac{4,260 + 5,552}{2} = 4,906 \text{ cm}.$$

$$\hat{G}(x) = \begin{cases} C_1, & x \leq 4,906 \text{ cm}, \\ C_2, & x > 4,906 \text{ cm}. \end{cases}$$

Minh họa phân loại 1 chiều: Versicolor và Virginica



Hai lớp có vùng chồng lấn quanh ngưỡng

$$x_{\text{bnd}} = 4,906 \text{ cm.}$$

Ma trận lỗi

	C_1	C_2
$\hat{C}_1$	48	6
$\hat{C}_2$	2	44

Tỷ lệ phân loại lỗi

$$\text{TPM} = \frac{6 + 2}{100} = 0,08 = 8\%.$$

Độ chính xác tổng thể

$$\text{Overall Accuracy} = 1 - \text{TPM} = 92\%.$$

	precision	recall
C_1	88,89%	96%
C_2	95,65%	88%

Minh họa phân loại 1 chiều: Setosa và Versicolor

Xét thuộc tính *Petal.Length* với hai lớp

$$C_1 = \textit{setosa}, \quad C_2 = \textit{versicolor}.$$

Từ dữ liệu Iris, ta có

$$n_1 = n_2 = 50, \quad \hat{\pi}_1 = \hat{\pi}_2 = \frac{1}{2}.$$

Trung bình mẫu và phương sai mẫu của hai lớp là


$$\hat{\mu}_1 = 1,462 \text{ cm}, \quad s_1^2 = 0,0302 \text{ cm}^2, \quad \hat{\mu}_2 = 4,260 \text{ cm}, \quad s_2^2 = 0,2208 \text{ cm}^2.$$

Vì $\hat{\pi}_1 = \hat{\pi}_2$, ngưỡng LDA là

$$x_{\text{bnd}} = \frac{1,462 + 4,260}{2} = 2,861 \text{ cm}.$$

$$\hat{G}(x) = \begin{cases} C_1, & x \leq 2,861 \text{ cm}, \\ C_2, & x > 2,861 \text{ cm}. \end{cases}$$

Minh họa phân loại 1 chiều: Setosa và Versicolor



Hai lớp tách biệt hoàn toàn theo *Petal.Length*;

$$x_{\text{bnd}} = 2,861 \text{ cm.}$$

Trong dữ liệu thực tế:

$$\max(\text{setosa}) = 1,9 \text{ cm,} \quad \min(\text{versicolor}) = 3,0 \text{ cm.}$$

Do đó, ngưỡng LDA nằm trong khoảng trống giữa hai lớp.

Ma trận lỗi

	C_1	C_2
$\widehat{C}_1$	50	0
$\widehat{C}_2$	0	50

Tỷ lệ phân loại lỗi

$$\text{TPM} = 0\%.$$

Độ chính xác tổng thể

$$\text{Accuracy} = 100\%.$$

	precision	recall
C_1	100%	100%
C_2	100%	100%

Mô phỏng hai chiều: Hai lớp ít chồng lấn

1. Thiết lập mô phỏng

$$n_1 = n_2 = 500, \quad \boldsymbol{\mu}_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \boldsymbol{\mu}_2 = \begin{pmatrix} 4 \\ 4 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 2 & -1,5 \\ -1,5 & 2 \end{pmatrix}.$$

2. Biên LDA lý thuyết

$$\boldsymbol{\beta}_{\text{opt}} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \begin{pmatrix} -2 \\ -2 \end{pmatrix}, \quad \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2} = \begin{pmatrix} 3,5 \\ 3,5 \end{pmatrix}.$$

$$\boldsymbol{\beta}_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2} \right) = 0 \quad \Rightarrow \quad -2x_1 - 2x_2 + 14 = 0$$

$$\Rightarrow \boxed{x_2 = 7 - x_1}.$$

3. Biên LDA thực nghiệm từ dữ liệu mẫu



$$\hat{\boldsymbol{\mu}}_1 = \begin{pmatrix} 3,0345 \\ 2,9611 \end{pmatrix}, \quad \hat{\boldsymbol{\mu}}_2 = \begin{pmatrix} 4,0687 \\ 3,9000 \end{pmatrix}, \quad \hat{\Sigma} = \begin{pmatrix} 2,2449 & -1,7388 \\ -1,7388 & 2,2465 \end{pmatrix}.$$

$$\mathbf{b}_{\text{opt}} = \hat{\Sigma}^{-1}(\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2) = \begin{pmatrix} -1,9587 \\ -1,9340 \end{pmatrix}.$$

$$\mathbf{b}_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\hat{\boldsymbol{\mu}}_1 + \hat{\boldsymbol{\mu}}_2}{2} \right) = 0 \quad \Rightarrow \quad -1,9587x_1 - 1,9340x_2 + 13,5912 = 0$$

$$\Rightarrow \boxed{x_2 = 7,0276 - 1,0128x_1}.$$

Mô phỏng hai chiều: Hai lớp ít chồng lấn



Kết quả đánh giá

$$\widehat{\text{TPM}} = 17,0\%, \quad \text{Accuracy} = 83,0\%.$$

	precision	recall
C_1	83,40%	82,40%
C_2	82,61%	83,60%

Mô phỏng hai chiều: Hai lớp chồng lấn nhiều

1. Thiết lập mô phỏng

$$n_1 = n_2 = 500, \quad \boldsymbol{\mu}_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \boldsymbol{\mu}_2 = \begin{pmatrix} 3,2 \\ 2,5 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

2. Biên LDA lý thuyết

$$\boldsymbol{\beta}_{\text{opt}} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \begin{pmatrix} -0,3 \\ 0,4 \end{pmatrix}, \quad \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2} = \begin{pmatrix} 3,1 \\ 2,75 \end{pmatrix}.$$

$$\boldsymbol{\beta}_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2} \right) = 0 \quad \Rightarrow \quad -0,3x_1 + 0,4x_2 - 0,17 = 0$$

$$\Rightarrow \quad \boxed{x_2 = 0,425 + 0,75x_1}.$$

3. Biên LDA thực nghiệm từ dữ liệu mẫu



$$\hat{\boldsymbol{\mu}}_1 = \begin{pmatrix} 2,9716 \\ 3,0225 \end{pmatrix}, \quad \hat{\boldsymbol{\mu}}_2 = \begin{pmatrix} 3,2101 \\ 2,5101 \end{pmatrix}, \quad \hat{\Sigma} = \begin{pmatrix} 1,9507 & 0,8710 \\ 0,8710 & 1,9595 \end{pmatrix}.$$

$$\mathbf{b}_{\text{opt}} = \hat{\Sigma}^{-1}(\hat{\boldsymbol{\mu}}_1 - \hat{\boldsymbol{\mu}}_2) = \begin{pmatrix} -0,2982 \\ 0,3940 \end{pmatrix}.$$

$$\mathbf{b}_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\hat{\boldsymbol{\mu}}_1 + \hat{\boldsymbol{\mu}}_2}{2} \right) = 0 \quad \Rightarrow \quad -0,2982x_1 + 0,3940x_2 - 0,1684 = 0$$

$$\Rightarrow \quad \boxed{x_2 = 0,4274 + 0,7567x_1}.$$

Mô phỏng hai chiều: Hai lớp chồng lẫn nhiều



Kết quả đánh giá

$\widehat{TPM} = 39,5\%$, Accuracy = 60,5%.

	precision	recall
C ₁	60,40%	61,0%
C ₂	60,61%	60,0%

Mô phỏng hai chiều: Hai lớp tách biệt hoàn toàn

1. Thiết lập mô phỏng

$$n_1 = n_2 = 500, \quad \mu_1 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}, \quad \mu_2 = \begin{pmatrix} 13 \\ 3 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}.$$

2. Biên LDA lý thuyết

Vì $\Sigma = 2I$, hai lớp có cùng phương sai theo hai hướng và không tương quan. Biên LDA lý thuyết là đường trung trực của đoạn nối hai tâm:

$$\beta_{\text{opt}} = \begin{pmatrix} -5 \\ 0 \end{pmatrix}, \quad \frac{\mu_1 + \mu_2}{2} = \begin{pmatrix} 8 \\ 3 \end{pmatrix}.$$

Áp dụng công thức đường biên:

$$\beta_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\mu_1 + \mu_2}{2} \right) = 0$$

$$\Rightarrow -5x_1 + 40 = 0 \Rightarrow \boxed{x_1 = 8}.$$

3. Biên LDA thực nghiệm từ dữ liệu mẫu

$$\hat{\mu}_1 = \begin{pmatrix} 2,9491 \\ 2,9966 \end{pmatrix}, \quad \hat{\mu}_2 = \begin{pmatrix} 12,9999 \\ 3,0117 \end{pmatrix}$$

$$\mathbf{b}_{\text{opt}} = \begin{pmatrix} -4,6356 \\ -0,0205 \end{pmatrix}.$$

$$\hat{\Sigma} = \begin{pmatrix} 2,1682 & -0,0051 \\ -0,0051 & 1,8841 \end{pmatrix}.$$


$$\mathbf{b}_{\text{opt}}^T \left(\mathbf{x}_{\text{bnd}} - \frac{\hat{\mu}_1 + \hat{\mu}_2}{2} \right) = 0$$

$$\Rightarrow -4,6356x_1 - 0,0205x_2 + 37,0283 = 0.$$


Vì hệ số của x_2 rất nhỏ nên biên thực nghiệm gần như là đường thẳng đứng:

$$\Rightarrow \boxed{x_1 \approx 7,9878}.$$

Mô phỏng hai chiều: Hai lớp tách biệt hoàn toàn



Hai lớp tách biệt rõ ràng; biên LDA gần với đường trung trực của hai tâm.



Kết quả đánh giá

$$\widehat{\text{TPM}} = 0\%, \quad \text{Accuracy} = 100\%.$$

	precision	recall
C_1	100%	100%
C_2	100%	100%

Kết quả đạt được

- Trình bày được cơ sở lý thuyết của Fisher LDA.
- Chứng minh phương chiều tối ưu trong trường hợp hai lớp.
- Làm rõ sự tương đồng giữa Fisher LDA và Bayes LDA.
- Minh họa bằng dữ liệu Iris và dữ liệu mô phỏng hai chiều cho phân loại hai lớp.

Hướng phát triển

- Mở rộng LDA cho bài toán nhiều lớp.
- So sánh LDA với các phương pháp phân loại mẫu thống kê khác.

Tài liệu tham khảo



Đặng Phước Huy, *Bài giảng tóm tắt – Thống kê toán học*, Trường Đại học Đà Lạt, 2010.



Đặng Phước Huy, *Bài giảng tóm tắt – Phân tích thống kê nhiều chiều*, Trường Đại học Đà Lạt, 2023.



Đặng Phước Huy, *Bài giảng tóm tắt – Lý thuyết học thống kê*, Trường Đại học Đà Lạt, 2025.



Lê Đình Phú, *Suy diễn thống kê với phương pháp mẫu nhỏ*, Khóa luận tốt nghiệp cử nhân toán học, Khoa Toán – Tin học, Trường Đại học Đà Lạt, 2022.



R. A. Fisher, *The Use of Multiple Measurements in Taxonomic Problems*, Annals of Eugenics, Vol. 7, No. 2, pp. 179–188, 1936.



Christopher M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.



Trevor Hastie, Robert Tibshirani, Jerome Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, 2009.



Johnson R. A., Wichern D. W., *Applied Multivariate Statistical Analysis*, Pearson Prentice Hall, Pearson Education, Inc, 2007.



R. A. Fisher, *Iris*, UCI Machine Learning Repository, 1936. DOI: <https://doi.org/10.24432/C56C76>.

Cảm ơn thầy cô và các bạn đã lắng nghe!